

# Итоговый проект по эконометрике Изучение и моделирование шоков на рынке нефти и их влияние на макроэкономические показатели на примере Германии

Дегтярев К.А. 1-й курс магистратуры ММЭ-1

```
# Считываем файлы с Data_from_Germany.xlsx:
read_excel_allsheets <- function(filename, tibble = FALSE) {
  sheets <- readxl::excel_sheets(filename)
  x <- lapply(sheets, function(X) readxl::read_excel(filename, sheet = X))
  if(!tibble) x <- lapply(x, as.data.frame)
  names(x) <- sheets
  x
}

df <- read_excel_allsheets("Data_from_Germany.xlsx")
```

## 0. Введение. Мотивирование работы.

Работа опирается на статью Cologni, A., & Manera, M. (2008). Oil prices, inflation and interest rates in a structural cointegrated VAR model for the G-7 countries. Energy Economics, 30(3), 856–888. doi:10.1016/j.eneco.2006.11.001 ссылка: <https://sci-hub.tw/10.1016/j.eneco.2006.11.001>

В ней рассматривается построение модели SVAR для стран G7 для группы показателей:

- Доходность по краткосрочным гос.облигациям, % доходность
- CPI(Индекс потребительских цен), индекс
- Реальный ВВП в постоянных ценах, миллион. национальная валюта
- Денежный агрегатор(M1),
- Отношение национальной курсы валюты к СДР(Специальные права заимствования), отношение
- Биржевая стоимость нефти марки Brent, долл.

Все данные квартальные. В статье рассматривался период(1980Q1 - 2003Q3)

Затем в статье рассматривается модель VECM для этих же показателей и моделируются шоки, которые оказывают изменение цены на нефть и на остальные показатели.

В итоговой работе рассмотрены упрощенные модели VAR, VECM, а также модель ARIMA и модели ECM, в соответствии с планом итогового проекта.

В проектной работе для построения моделей используются те же переменные, но взятые с 1994Q и до 2018Q2, на примере Германии. Также логирифируются некоторые переменные, исходя из экономического смысла. Главная цель работы - составить модель распространения шоков цены на нефть на другие макроэкономические

факторы, в особенности - на доходность гос. облигаций. Также в конце будут сравнены полученные результаты в проектной работе на современных данных с выводами авторов статьи и сделаны соответствующие выводы.

Источники информации:

- Доходность по краткосрочным гос.облигациям - терминал Bloomberg(тикер: GDBR2:IND)
- CPI - worldbank
- Реальный GDP - eurostat(запрос: Chain linked volumes)
- Денежный агрегатор(M1) - IMF
- Отношение национальной курсы валюты к СДР - eurostat
- Биржевая стоимость нефти марки Brent - терминал Bloomberg(тикер: CO1:COM)

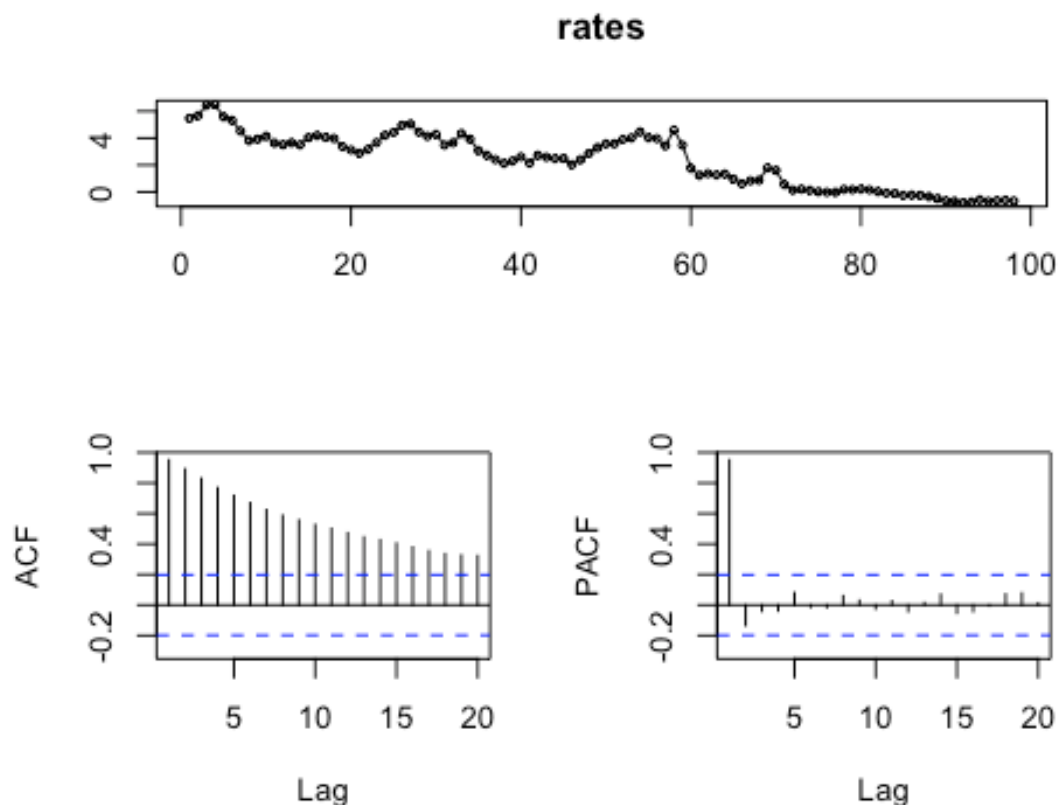
## 1. Обработка переменных и определение порядка интегрируемости рядов

*# Короткосрочная ставка:*

```
dates <- as.yearqtr(df$`Germany Bund 2 Year Yield`$Date, format = "%Y-%m-%d")
rates <- zooreg(df$`Germany Bund 2 Year Yield`$PX_LAST, order.by = dates)
```

Warning in zoo(data, order.by, frequency): "order.by" and "frequency" do not match: "frequency" ignored

```
tsdisplay(rates)
```

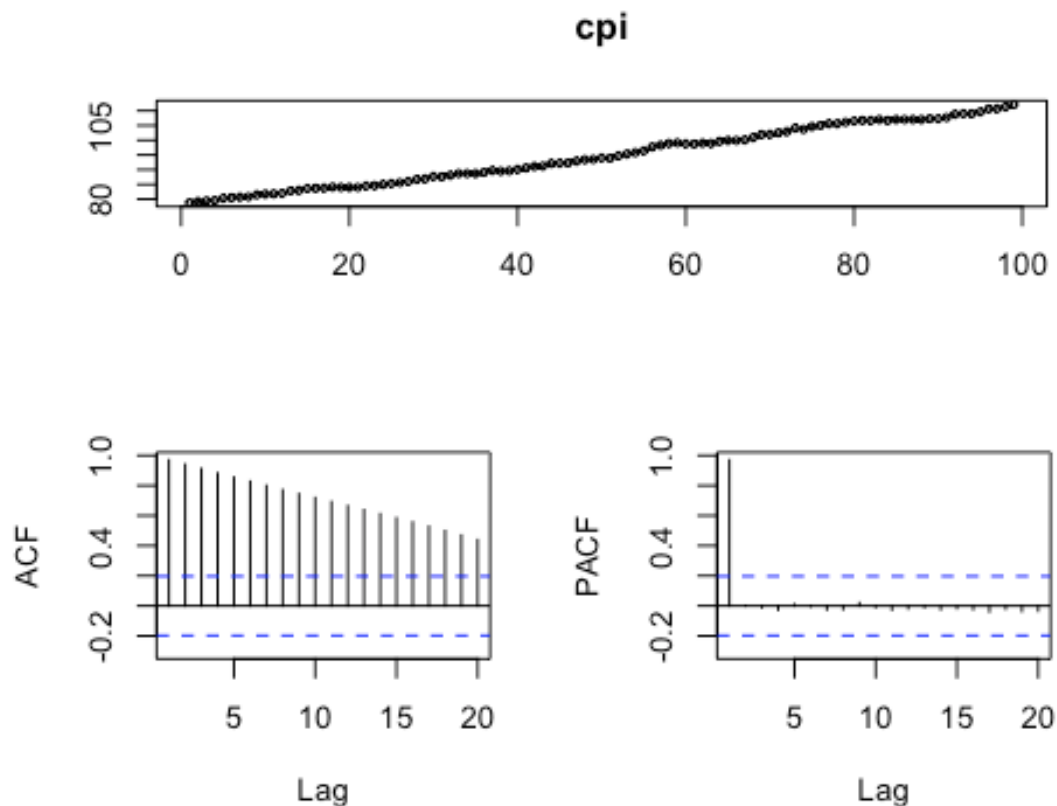


*# Индекс CPI:*

```
dates <- as.yearqtr(df$CPI_quater$Quarter, format = "%Y-%m-%d")  
cpi <- zooreg(df$CPI_quater$CPI, order.by = dates)
```

Warning in zoo(data, order.by, frequency): "order.by" and "frequency" do not match: "frequency" ignored

```
tsdisplay(cpi)
```

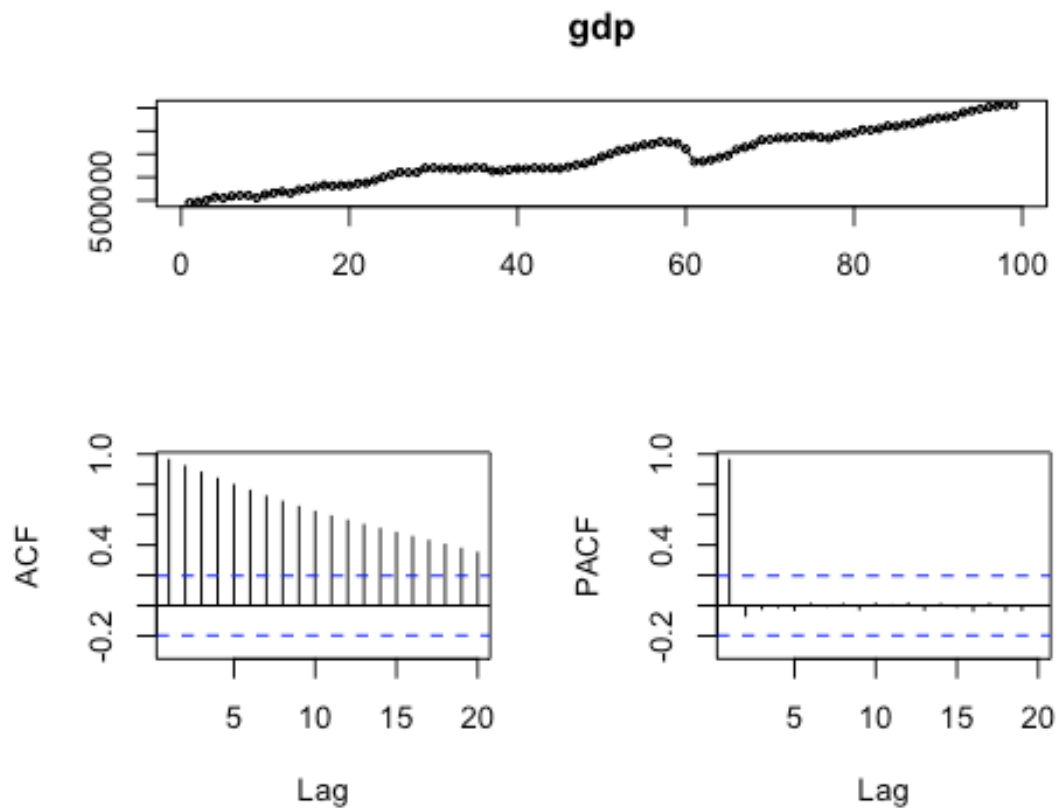


*# Реальный ВВП в постоянных ценах 2005 г. в национальной валюте*

```
dates <- as.yearqtr(df$GDP_2005localCurrency$Date, format = "%Y-%m-%d")  
gdp <- zooreg(df$GDP_2005localCurrency$PX_LAST, order.by = dates)
```

Warning in zoo(data, order.by, frequency): "order.by" and "frequency" do not match: "frequency" ignored

```
tsdisplay(gdp)
```




*# Денежный агрегатор M1 в национальной валюте:*

```
dates <- as.yearqtr(df$M1_quater$Date, format = "%Y-%m")
```

```
m1 <- zooreg(df$M1_quater$M1, order.by = dates)
```

Warning in zoo(data, order.by, frequency): "order.by" and "frequency" do not match: "frequency" ignored

```
tsdisplay(m1)
```



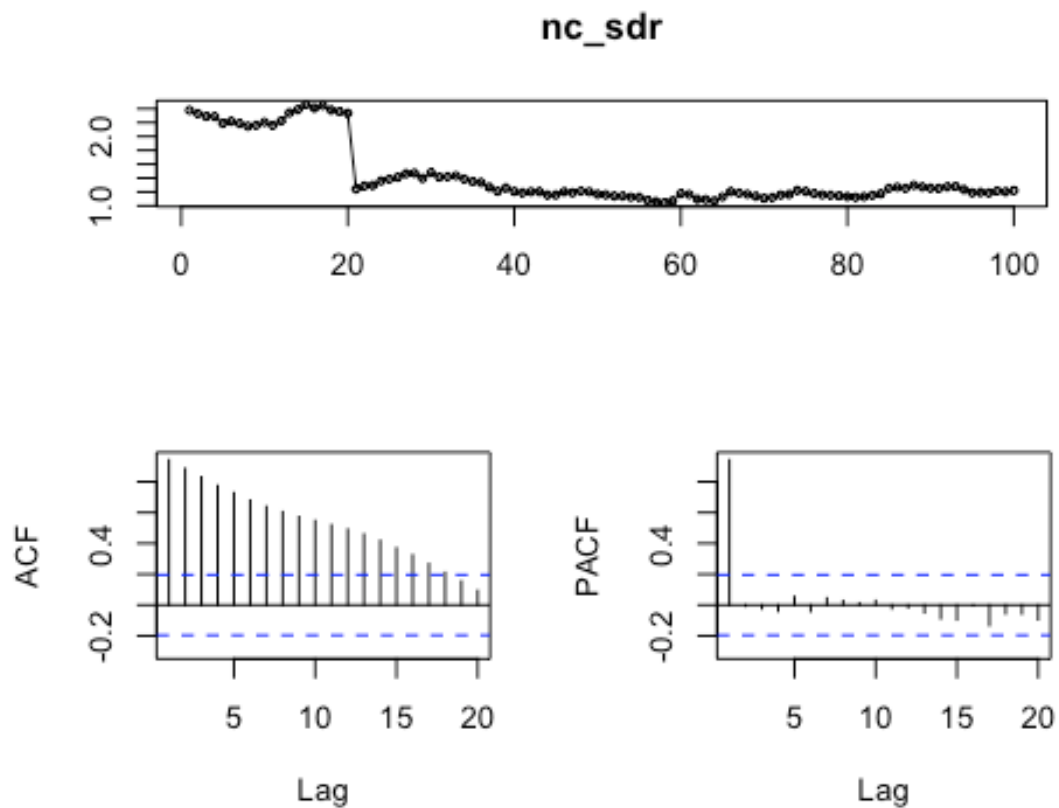
```
# Национальная валюта / SDR
```

```
dates1 <- as.yearqtr(df$Cur_SDR$Date, format = "%Y-%m-%d")
```

```
nc_sdr <- zooreg(df$Cur_SDR$NC_SDR, order.by = dates1)
```

```
Warning in zoo(data, order.by, frequency): "order.by" and "frequency" do
not match: "frequency" ignored
```

```
tsdisplay(nc_sdr)
```




```
# Brent
```

```
dates <- as.yearqtr(df$BRENT_QUATER$`<DATE>`, format = "%d.%m.%Y")
brent <- zooreg(df$BRENT_QUATER$`<CLOSE>`, order.by = dates)
```

```
Warning in zoo(data, order.by, frequency): "order.by" and "frequency" do
not match: "frequency" ignored
```

```
tsdisplay(brent)
```



Получились разные количества доступных наблюдений для каждой переменной, поэтому возьмем наименьшее количество наблюдений, чтобы были включены все переменные, сократим временной интервал до 2-го квартала 2018-го года:

```
cpi <- cpi[1:length(cpi)-1]
gdp <- gdp[1:length(gdp)-1]
m1 <- m1[1:length(m1)-1]
nc_sdr <- nc_sdr[2:length(nc_sdr)-2]
brent <- brent[2:length(brent)-2]
```

Исходя из методологии исследователей из статьи, прологарифмируем все переменные за исключение доходности(rates), отношения NC/SDR(nc\_sdr), цены нефти марки brent(brent):

```
ln_cpi <- log(cpi)
ln_gdp <- log(gdp)
ln_m1 <- log(m1)
```

Как видно из вышепредставленных графиков временных рядов, ACF и PACF - все ряды нестационарны. Проведем тесты ADF, PP-теста, для того, чтобы определить порядок интегрируемости, а также проверим остатки вспомогательной модели на наличие автокорреляции с помощью теста Льюинга-Бокса. Напомним, что в тесте ADF H0: наличие единичного корня. Полученная тестовая статистика сравнивается с критическими значениями MacKinnon. Если t-статистика < критического значения MacKinnon, то гипотеза о наличии единичного корня отвергается(ряд стационарен). В

PP-тесте  $H_0$  = наличие стационарности, а в тесте Льюинга-Бокса  $H_0$  = ряд представляет собой белый шум, т.е. нет автокорреляции в остатках. Результаты тестов, представлены ниже:

```
# Ряд доходностей 2-х летних гос. облигаций
```

```
test <- (ur.df(rates, type = "trend"))
```

```
Box.test(test$res, type= "Ljung-Box")
```

Box-Ljung test

```
data: test$res
```

```
X-squared = 0.00018315, df = 1, p-value = 0.9892
```

```
summary(test)
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-1.10704	-0.16327	-0.02884	0.19471	1.60329

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	0.826668	0.294504	2.807	0.00610	**
z.lag.1	-0.162430	0.051156	-3.175	0.00204	**
tt	-0.010023	0.003574	-2.805	0.00615	**
z.diff.lag	0.253927	0.100587	2.524	0.01330	*

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4151 on 92 degrees of freedom

Multiple R-squared: 0.126, Adjusted R-squared: 0.09747

F-statistic: 4.42 on 3 and 92 DF, p-value: 0.00598

Value of test-statistic is: -3.1752 3.9213 5.0525

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-4.04	-3.45	-3.15
phi2	6.50	4.88	4.16
phi3	8.73	6.49	5.47



```
pp.test(as.numeric(rates))
```

Phillips-Perron Unit Root Test  
alternative: stationary

Type 1: no drift no trend

lag	Z_rho	p.value
3	-2.67	0.346

-----

Type 2: with drift no trend

lag	Z_rho	p.value
3	-2.79	0.675

-----

Type 3: with drift and trend

lag	Z_rho	p.value
3	-15.7	0.182

-----

Note: p-value = 0.01 means p.value <= 0.01

Как видно из результатов тестов ряд rates получился нестационарным, т.к. Value of test-statistic (-3.1752) > Critical values tau3 (-3.45) на 5% значимости, что означает, что гипотеза о наличии единичного корня не отвергается. Остальные значения тестовой статистики(phi2, phi3) говорят о целесообразности включения в модель дрефта и тренда.

PP-тест, также показал, что присутствует автокорреляция с p-значением большим 0,05 во всех трех спецификациях теста.

В остатках из вспомогательной модели к тесту ADF отвергается гипотеза о наличие автокорреляции(p-value = 0.9892), поэтому результаты ADF теста можно считать достоверными.

Проведем те же самые тесты для первой разности ряда rates:

```
# 1-й разность доходностей 2-х летних гос. облигаций
test <- (ur.df(diff(rates), type = "trend"))
Box.test(test$res, type= "Ljung-Box")
```

Box-Ljung test

data: test\$res

X-squared = 6.8514e-05, df = 1, p-value = 0.9934

```
summary(test)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

```

Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-1.35540 -0.18768  0.02253  0.18797  1.32294

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.1102663   0.0899335  -1.226   0.223
z.lag.1      -0.9674543   0.1304176  -7.418 6.03e-11 ***
tt           0.0007714   0.0015930   0.484   0.629
z.diff.lag   0.1546488   0.1013220   1.526   0.130
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4257 on 91 degrees of freedom
Multiple R-squared:  0.4451,    Adjusted R-squared:  0.4268
F-statistic: 24.33 on 3 and 91 DF,  p-value: 1.195e-11

```

Value of test-statistic is: -7.4181 18.4127 27.5961

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-4.04	-3.45	-3.15
phi2	6.50	4.88	4.16
phi3	8.73	6.49	5.47

```
pp.test(as.numeric(diff(rates)))
```

Phillips-Perron Unit Root Test  
alternative: stationary

Type 1: no drift no trend

lag	Z_rho	p.value
3	-73.3	0.01

-----

Type 2: with drift no trend

lag	Z_rho	p.value
3	-73.6	0.01

-----

Type 3: with drift and trend

lag	Z_rho	p.value
3	-73.5	0.01

-----

Note: p-value = 0.01 means p.value <= 0.01

Из результатов обоих тестов видно, что первая разность ряда *rates* стационарна (из ADF: test-statistic -7.4181 < -3.45 и из PP-теста p-value < 0.05). Таким образом, *rates* —  $I(1)$ .

Аналогичным образом проведем тесты для других рядов:

```
# Ряд ln_CPI
test <- (ur.df(ln_cpi, type = "trend"))
Box.test(test$res, type = "Ljung-Box")

Box-Ljung test

data: test$res
X-squared = 0.0024613, df = 1, p-value = 0.9604

summary(test)

#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression trend

Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-0.0058808 -0.0026170 -0.0005155  0.0021950  0.0103519

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.3726432  0.1992325   1.870   0.0646 .
z.lag.1      -0.0845037  0.0456836  -1.850   0.0676 .
tt           0.0003036  0.0001676   1.812   0.0733 .
z.diff.lag   -0.0384492  0.1051898  -0.366   0.7156
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.003509 on 92 degrees of freedom
Multiple R-squared:  0.0442,    Adjusted R-squared:  0.01304
F-statistic: 1.418 on 3 and 92 DF,  p-value: 0.2425

Value of test-statistic is: -1.8498 20.1745 1.7993

Critical values for test statistics:
      1pct  5pct 10pct
tau3 -4.04 -3.45 -3.15
phi2  6.50  4.88  4.16
phi3  8.73  6.49  5.47

pp.test(as.numeric(ln_cpi))
```

Phillips-Perron Unit Root Test  
alternative: stationary

Type 1: no drift no trend

lag	Z_rho	p.value
3	0.0759	0.706

-----

Type 2: with drift no trend

lag	Z_rho	p.value
3	-0.199	0.944

-----

Type 3: with drift and trend

lag	Z_rho	p.value
3	-9.3	0.484

-----

Note: p-value = 0.01 means p-value <= 0.01

*# ln\_CPI 1-я разность*

```
test <- (ur.df(diff(ln_cpi), type = "trend"))  
Box.test(test$res, type= "Ljung-Box")
```

Box-Ljung test

data: test\$res

X-squared = 0.0013264, df = 1, p-value = 0.9709

summary(test)

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.0067863	-0.0029291	-0.0004679	0.0021863	0.0099982

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	3.936e-03	9.577e-04	4.110	8.65e-05	***
z.lag.1	-1.027e+00	1.542e-01	-6.658	2.05e-09	***
tt	-5.893e-06	1.345e-05	-0.438	0.662	
z.diff.lag	-5.276e-02	1.050e-01	-0.503	0.616	

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.003586 on 91 degrees of freedom  
Multiple R-squared: 0.5426, Adjusted R-squared: 0.5275  
F-statistic: 35.98 on 3 and 91 DF, p-value: 2.003e-15

Value of test-statistic is: -6.6581 14.777 22.1655

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-4.04	-3.45	-3.15
phi2	6.50	4.88	4.16
phi3	8.73	6.49	5.47

```
pp.test(as.numeric(diff(ln_cpi)))
```

Phillips-Perron Unit Root Test  
alternative: stationary

Type 1: no drift no trend

lag	Z_rho	p.value
3	-52	0.01

-----

Type 2: with drift no trend

lag	Z_rho	p.value
3	-108	0.01

-----

Type 3: with drift and trend

lag	Z_rho	p.value
3	-109	0.01

-----

Note: p-value = 0.01 means p.value <= 0.01

*# Получился I(1)*

*# Ряд Ln\_GDP*

```
test <- (ur.df(ln_gdp, type = "trend"))  
Box.test(test@res, type= "Ljung-Box")
```

Box-Ljung test

data: test@res  
X-squared = 0.354, df = 1, p-value = 0.5519

```
summary(test)
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.040629	-0.003422	0.000397	0.003611	0.016327

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	1.8030983	0.5712079	3.157	0.002158	**
z.lag.1	-0.1372241	0.0435296	-3.152	0.002186	**
tt	0.0004558	0.0001463	3.116	0.002444	**
z.diff.lag	0.3807364	0.0968067	3.933	0.000163	***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.007391 on 92 degrees of freedom

Multiple R-squared: 0.1844, Adjusted R-squared: 0.1578

F-statistic: 6.931 on 3 and 92 DF, p-value: 0.0002941

Value of test-statistic is: -3.1524 6.4589 4.9741

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-4.04	-3.45	-3.15
phi2	6.50	4.88	4.16
phi3	8.73	6.49	5.47

`pp.test(as.numeric(ln_gdp))`

Phillips-Perron Unit Root Test

alternative: stationary

Type 1: no drift no trend

lag	Z_rho	p.value
3	0.0269	0.695

-----

Type 2: with drift no trend

lag	Z_rho	p.value
3	-0.444	0.927

-----

Type 3: with drift and trend

lag	Z_rho	p.value
3	-16.1	0.163

-----

Note: p-value = 0.01 means p.value <= 0.01

```
# ln_GDP 1-я разность
test <- (ur.df(diff(ln_gdp), type = "trend"))
Box.test(test$res, type= "Ljung-Box")
```

Box-Ljung test

```
data: test$res
X-squared = 0.00509, df = 1, p-value = 0.9431
```

```
summary(test)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

```
Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

```
Residuals:
      Min       1Q   Median       3Q      Max
-0.042376 -0.003538  0.000537  0.004173  0.015388
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.128e-03  1.695e-03   1.255    0.213
z.lag.1      -6.605e-01  1.228e-01  -5.377 5.81e-07 ***
tt           5.505e-06  2.919e-05   0.189    0.851
z.diff.lag   -4.275e-02  1.046e-01  -0.409    0.684
---

```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.007802 on 91 degrees of freedom
Multiple R-squared:  0.347, Adjusted R-squared:  0.3255
F-statistic: 16.12 on 3 and 91 DF, p-value: 1.749e-08
```

Value of test-statistic is: -5.3771 9.6424 14.4627

Critical values for test statistics:

```
      1pct  5pct 10pct
tau3 -4.04 -3.45 -3.15
phi2  6.50  4.88  4.16
phi3  8.73  6.49  5.47
```

```
pp.test(as.numeric(diff(ln_gdp)))
```

Phillips-Perron Unit Root Test  
alternative: stationary

Type 1: no drift no trend

lag	Z_rho	p.value
3	-55.8	0.01

-----

Type 2: with drift no trend

lag	Z_rho	p.value
3	-67.8	0.01

-----

Type 3: with drift and trend

lag	Z_rho	p.value
3	-67.8	0.01

-----

Note: p-value = 0.01 means p-value <= 0.01

# Получился  $I(1)$

# Ряд  $ln\_M1$

```
test <- (ur.df(ln_m1, type = "trend"))  
Box.test(test$res, type= "Ljung-Box")
```

Box-Ljung test

data: test\$res

X-squared = 0.0026347, df = 1, p-value = 0.9591

```
summary(test)
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.048239	-0.012017	-0.001865	0.008188	0.166768

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	0.9345697	0.5175021	1.806	0.0742 .
z.lag.1	-0.0611242	0.0346961	-1.762	0.0814 .
tt	0.0002863	0.0003151	0.909	0.3660
z.diff.lag	-0.1919808	0.1012878	-1.895	0.0612 .



```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.0249 on 92 degrees of freedom
Multiple R-squared:  0.1206,    Adjusted R-squared:  0.09193
F-statistic: 4.206 on 3 and 92 DF,  p-value: 0.007779
```

```
Value of test-statistic is: -1.7617 8.2525 4.9174
```

```
Critical values for test statistics:
```

```
      1pct  5pct 10pct
tau3 -4.04 -3.45 -3.15
phi2  6.50  4.88  4.16
phi3  8.73  6.49  5.47
```

```
pp.test(as.numeric(ln_m1))
```

```
Phillips-Perron Unit Root Test
alternative: stationary
```

```
Type 1: no drift no trend
```

```
lag Z_rho p.value
 3 0.0558  0.701
```

```
-----
```

```
Type 2: with drift no trend
```

```
lag Z_rho p.value
 3 -2.45  0.714
```

```
-----
```

```
Type 3: with drift and trend
```

```
lag Z_rho p.value
 3 -5.74  0.746
```

```
-----
```

```
Note: p-value = 0.01 means p.value <= 0.01
```

```
# Ln_M1 1-я разность
```

```
test <- (ur.df(diff(ln_m1), type = "trend"))
```

```
Box.test(test@res, type= "Ljung-Box")
```

```
Box-Ljung test
```

```
data: test@res
```

```
X-squared = 0.0033286, df = 1, p-value = 0.954
```

```
summary(test)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

```
Test regression trend
```

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.049132	-0.012707	-0.001505	0.008799	0.169295

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	0.0234687	0.0061830	3.796	0.000265 ***
z.lag.1	-1.2411504	0.1637449	-7.580	2.81e-11 ***
tt	-0.0002536	0.0001009	-2.514	0.013709 *
z.diff.lag	0.0172592	0.1048282	0.165	0.869590

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02543 on 91 degrees of freedom

Multiple R-squared: 0.6098, Adjusted R-squared: 0.5969

F-statistic: 47.4 on 3 and 91 DF, p-value: < 2.2e-16

Value of test-statistic is: -7.5798 19.1513 28.7266

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-4.04	-3.45	-3.15
phi2	6.50	4.88	4.16
phi3	8.73	6.49	5.47

```
pp.test(as.numeric(diff(ln_m1)))
```

Phillips-Perron Unit Root Test

alternative: stationary

Type 1: no drift no trend

lag	Z_rho	p.value
3	-117	0.01

-----

Type 2: with drift no trend

lag	Z_rho	p.value
3	-123	0.01

-----

Type 3: with drift and trend

lag	Z_rho	p.value
3	-124	0.01

-----

Note: p-value = 0.01 means p.value <= 0.01

# Получился  $I(1)$

```
# Ряд Ln_NC_SDR
test <- (ur.df(nc_sdr, type = "trend"))
Box.test(test$res, type = "Ljung-Box")
```

Box-Ljung test

```
data: test$res
X-squared = 3.6615e-05, df = 1, p-value = 0.9952
```

```
summary(test)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

```
Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-1.02214 -0.02217  0.00667  0.03359  0.17294
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.1260256  0.0869961   1.449   0.1508
z.lag.1      -0.0794700  0.0411617  -1.931   0.0566 .
tt           -0.0004807  0.0006550  -0.734   0.4648
z.diff.lag   0.0094196  0.1041196   0.090   0.9281
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.1175 on 92 degrees of freedom
Multiple R-squared:  0.05056,    Adjusted R-squared:  0.0196
F-statistic: 1.633 on 3 and 92 DF,  p-value: 0.1871
```

Value of test-statistic is: -1.9307 1.9437 2.4343

Critical values for test statistics:

```
      1pct  5pct 10pct
tau3 -4.04 -3.45 -3.15
phi2  6.50  4.88  4.16
phi3  8.73  6.49  5.47
```

```
pp.test(as.numeric(nc_sdr))
```

Phillips-Perron Unit Root Test  
alternative: stationary

Type 1: no drift no trend

lag	Z_rho	p.value
3	-1.21	0.47

-----

Type 2: with drift no trend

lag	Z_rho	p.value
3	-5.48	0.43

-----

Type 3: with drift and trend

lag	Z_rho	p.value
3	-7.97	0.575

-----

Note: p-value = 0.01 means p-value <= 0.01

*# Ln\_NC\_SDR 1-я разность*

```
test <- (ur.df(diff(nc_sdr), type = "trend"))  
Box.test(test$res, type= "Ljung-Box")
```

Box-Ljung test

data: test\$res

X-squared = 1.6773e-06, df = 1, p-value = 0.999

summary(test)

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

Min	1Q	Median	3Q	Max
-1.06670	-0.01771	0.00211	0.03443	0.14807

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	-0.0343123	0.0258265	-1.329	0.187
z.lag.1	-1.0317187	0.1504082	-6.859	8.14e-10 ***
tt	0.0004615	0.0004557	1.013	0.314
z.diff.lag	0.0022700	0.1048428	0.022	0.983

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1205 on 91 degrees of freedom  
Multiple R-squared: 0.5146, Adjusted R-squared: 0.4986  
F-statistic: 32.16 on 3 and 91 DF, p-value: 2.893e-14

Value of test-statistic is: -6.8595 15.686 23.5261

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-4.04	-3.45	-3.15
phi2	6.50	4.88	4.16
phi3	8.73	6.49	5.47

```
pp.test(as.numeric(diff(nc_sdr)))
```

Phillips-Perron Unit Root Test  
alternative: stationary

Type 1: no drift no trend

lag	Z_rho	p.value
3	-97.8	0.01

-----

Type 2: with drift no trend

lag	Z_rho	p.value
3	-98.1	0.01

-----

Type 3: with drift and trend

lag	Z_rho	p.value
3	-98.4	0.01

-----

Note: p-value = 0.01 means p-value <= 0.01

*# Получился I(1)*

*# Ряд Ln\_brent*

```
test <- (ur.df(brent, type = "trend"))  
Box.test(test@res, type= "Ljung-Box")
```

Box-Ljung test

data: test@res  
X-squared = 0.10853, df = 1, p-value = 0.7418

```
summary(test)
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

Min	1Q	Median	3Q	Max
-42.994	-3.858	-0.272	4.819	43.758

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	2.20784	2.42162	0.912	0.36430
z.lag.1	-0.13522	0.05074	-2.665	0.00909 **
tt	0.11343	0.06137	1.848	0.06778 .
z.diff.lag	0.14260	0.10404	1.371	0.17383

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 11.34 on 92 degrees of freedom

Multiple R-squared: 0.07665, Adjusted R-squared: 0.04654

F-statistic: 2.546 on 3 and 92 DF, p-value: 0.06082

Value of test-statistic is: -2.6651 2.4649 3.563

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-4.04	-3.45	-3.15
phi2	6.50	4.88	4.16
phi3	8.73	6.49	5.47

`pp.test(as.numeric(brent))`

Phillips-Perron Unit Root Test

alternative: stationary

Type 1: no drift no trend

lag	Z_rho	p.value
3	-0.591	0.557

-----

Type 2: with drift no trend

lag	Z_rho	p.value
3	-5.39	0.436

-----

Type 3: with drift and trend

lag	Z_rho	p.value
3	-11.2	0.397

-----

Note: p-value = 0.01 means p-value <= 0.01

```
# ln_NC_SDR 1-я разность
test <- (ur.df(diff(brent), type = "trend"))
Box.test(test$res, type= "Ljung-Box")
```

Box-Ljung test

```
data: test$res
X-squared = 0.003981, df = 1, p-value = 0.9497
```

```
summary(test)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

```
Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-43.720	-3.566	-0.195	5.006	42.028

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	1.3713	2.3846	0.575	0.56668
z.lag.1	-1.2001	0.1373	-8.740	1.1e-13 ***
tt	-0.0123	0.0424	-0.290	0.77231
z.diff.lag	0.2919	0.1006	2.901	0.00467 **

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 11.32 on 91 degrees of freedom  
Multiple R-squared: 0.5079, Adjusted R-squared: 0.4917  
F-statistic: 31.31 on 3 and 91 DF, p-value: 5.361e-14

Value of test-statistic is: -8.74 25.4728 38.2052

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-4.04	-3.45	-3.15
phi2	6.50	4.88	4.16
phi3	8.73	6.49	5.47

```
pp.test(as.numeric(diff(brent)))
```

```
Phillips-Perron Unit Root Test
alternative: stationary
```

```
Type 1: no drift no trend
```

```
lag Z_rho p.value
  3 -76.5    0.01
```

```
-----
```

```
Type 2: with drift no trend
```

```
lag Z_rho p.value
  3 -76.5    0.01
```

```
-----
```

```
Type 3: with drift and trend
```

```
lag Z_rho p.value
  3 -76.5    0.01
```

```
-----
```

```
Note: p-value = 0.01 means p.value <= 0.01
```

```
# Получился  $I(1)$ 
```

Таким образом все остальные логарифмы рядов получились  $I(1)$ .

```
d_rates <- diff(rates)
d_ln_cpi <- diff(ln_cpi)
d_ln_gdp <- diff(ln_gdp)
d_ln_m1 <- diff(ln_m1)
d_nc_sdr <- diff(nc_sdr)
d_brent <- diff(brent)
```

## 2. Построение модели ARIMA и прогноз по ней на 1 шаг вперед.

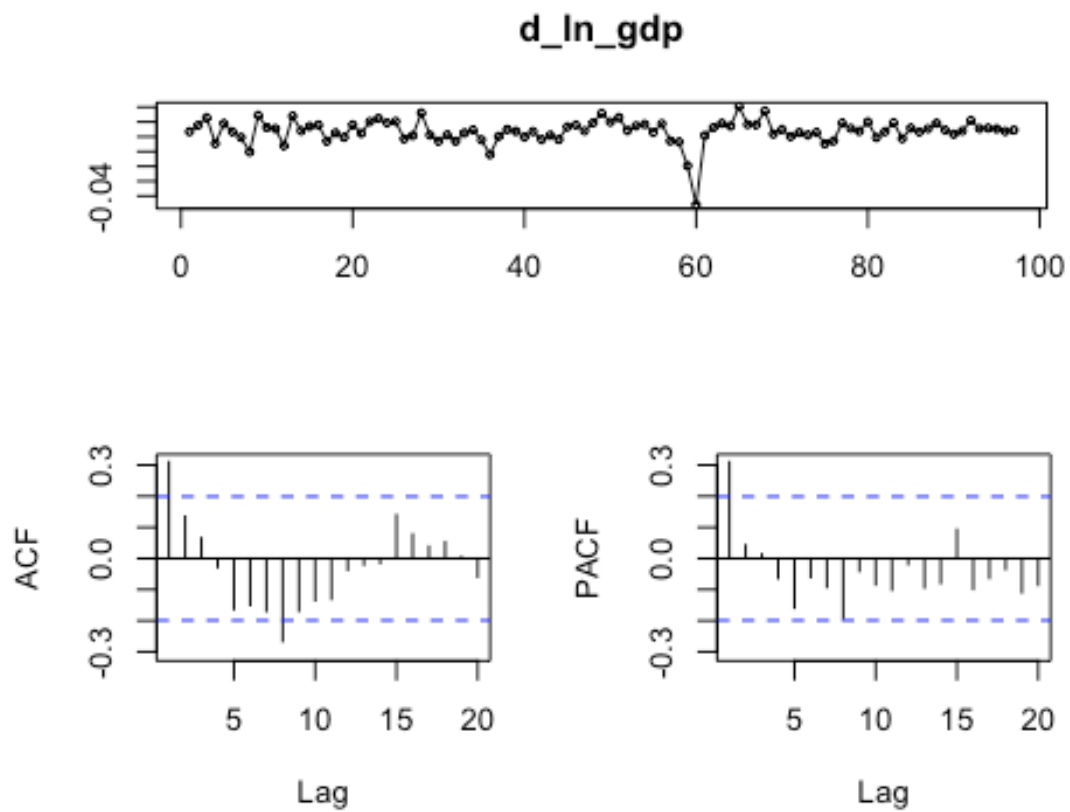
Построим модель ARIMA для `ln_gdp`.

Для построения данной модели воспользуемся методологией Бокса-Дженкинса:

1. Порядок интегрируемости для ряда `ln_gdp`, как было уже ранее установлено, равен 1.
2. Для определения  $p, q$  в ARIMA  $(p,1,q)$  построим ACF и PACF для первой разности нашего ряда:

```
tsdisplay(d_ln_gdp)
```

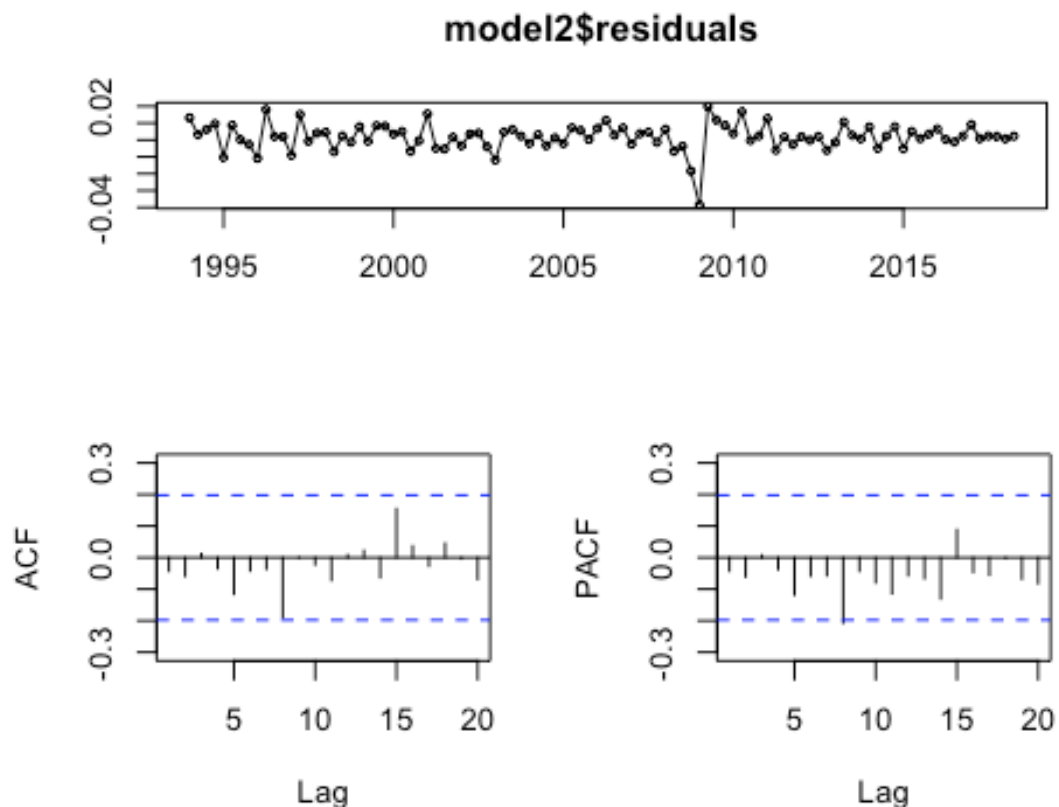




В соответствии с графиком PACF возьмем лаги для AR = (1)

В соответствии с графиком ACF возьмем лаги для MA = (1)

```
model2 <- arima(ln_gdp, order = c(1,1,1), include.mean = T)
tsdisplay(model2$residuals)
```



```
summary(model2)
```

Call:

```
arima(x = ln_gdp, order = c(1, 1, 1), include.mean = T)
```

Coefficients:

```
      ar1      ma1
      0.6784 -0.3143
s.e.  0.1569  0.2020
```

sigma^2 estimated as 6.164e-05: log likelihood = 332.41, aic = -658.83

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE
Training set	0.001872177	0.007922171	0.005668168	0.014099	0.04271741
	MASE	ACF1			
Training set	0.8853683	-0.04238953			

```
coeftest(model2)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )
ar1	0.67841	0.15692	4.3232	1.538e-05 ***

```
ma1 -0.31434    0.20205 -1.5558    0.1198
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

С помощью функции `auto.arima` определим модель с лучшими информационными критериями:

```
model3 <- auto.arima(d_ln_gdp, stepwise = FALSE, parallel = T, test = c("kpss",  
"adf", "pp"),  
ic = c("aicc", "aic", "bic"), stationary = T, approximation = F, seasonal = F)  
summary(model3)
```

```
Series: d_ln_gdp  
ARIMA(1,0,0) with non-zero mean
```

```
Coefficients:
```

```
      ar1      mean  
      0.3069  0.0037  
s.e.  0.0959  0.0011
```

```
sigma^2 estimated as 5.862e-05:  log likelihood=335.93  
AIC=-665.85  AICc=-665.6  BIC=-658.13
```

```
Training set error measures:
```

```
              ME          RMSE          MAE          MPE          MAPE  
Training set 3.226257e-07 0.007577179 0.005103156 74.33587 203.1668  
              MASE          ACF1  
Training set 0.6697823 -0.01000973
```

```
coeftest(model3)
```

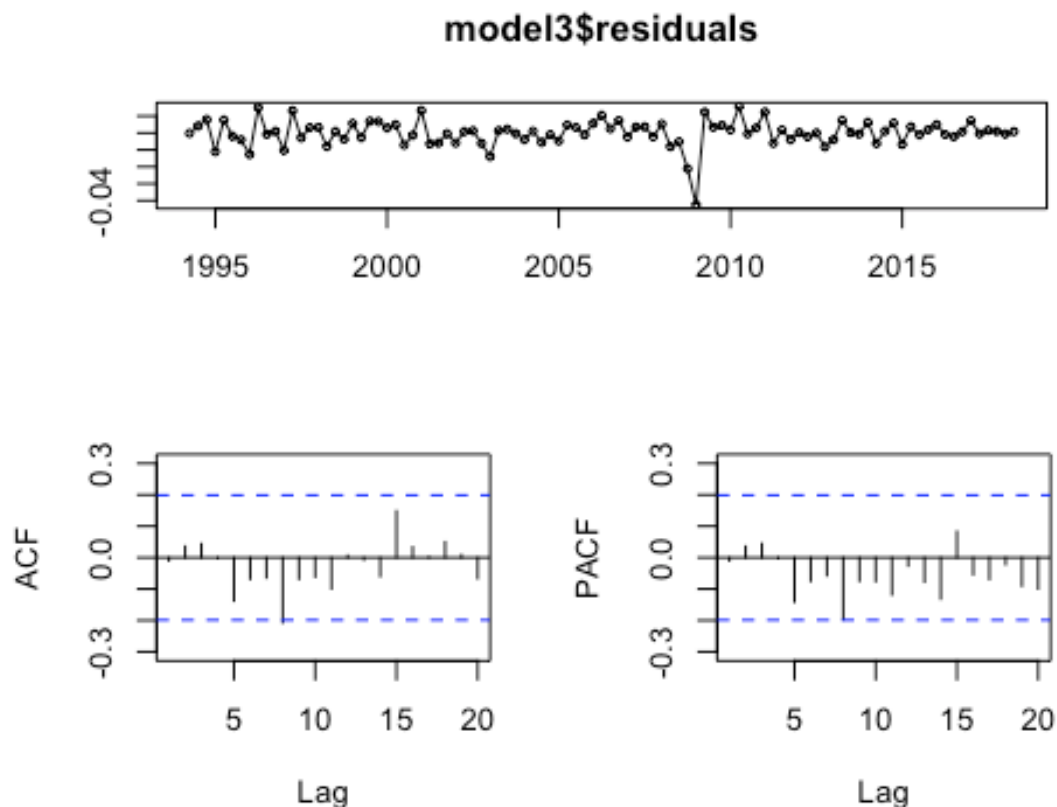
```
z test of coefficients:
```

```
      Estimate Std. Error z value Pr(>|z|)  
ar1      0.3069318  0.0959129  3.2001 0.0013738 **  
intercept 0.0036905  0.0011097  3.3258 0.0008817 ***
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
tsdisplay(model3$residuals)
```



Таким образом получилась модель ARIMA(1,1,0):

$$y_t = 0.0037 + 0.3069y_{t-1} + \varepsilon_t$$

Проверим с помощью теста Льюинга-Бокса на автокорреляцию в остатках:

```
Box.test(model3$residuals, type = "Ljung-Box", lag = 10, fitdf = 1)
```

Box-Ljung test

```
data: model3$residuals
X-squared = 8.8084, df = 9, p-value = 0.4551
```

На 5% уровне значимости отвергается гипотеза о наличии автокорреляции в остатках модели.

Проведем тест на нормальность остатков с помощью теста Shapiro-Wilk:

```
shapiro.test(model3$residuals)
```

Shapiro-Wilk normality test

```
data: model3$residuals
W = 0.87466, p-value = 1.536e-07
```

К сожалению, тест показывает, что на 5% уровне значимости не отвергается гипотеза о наличии автокорреляции в остатках модели. Это можно объяснить небольшой выборкой.

Проверим на обратимость нашу модель ARIMA(1,1,0):

Уравнение нашего временного ряда исходя из итоговой модели можно представить в виде:

$$y_t = 0.0037 + 0.3069y_{t-1} + \varepsilon_t$$

Процесс AR всегда обратим => вся модель ARIMA(1,1,0) также обратима и стационарна => Таким образом, получается, что наш процесс ARIMA(0,1,1) обратим и стационарен и можно делать прогнозы по данной модели.

Построим прогноз на 1 день вперед с доверительными интервалами:

```
future <- forecast::forecast(model3, h = 1)
print(future)
```

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
2018 Q3	0.003940717	-0.005871513	0.01375295	-0.01106579	0.01894723

### 3. Модель VAR.

Создадим матрицу переменных, т.е. предположим, что все переменные в модели VAR эндогенные и выберем порядок лага для модели VAR:

```
varmat <- as.matrix(cbind(d_rates, d_ln_cpi, d_ln_gdp, d_ln_m1, d_nc_sdr, d_brent))
```

```
VARselect(varmat, lag.max = 4, type= "trend")
```

```
$selection
```

AIC(n)	HQ(n)	SC(n)	FPE(n)
1	1	1	1

```
$criteria
```

	1	2	3	4
AIC(n)	-2.948922e+01	-2.941928e+01	-2.906721e+01	-2.891189e+01
HQ(n)	-2.902741e+01	-2.856162e+01	-2.781371e+01	-2.726255e+01
SC(n)	-2.834547e+01	-2.729516e+01	-2.596274e+01	-2.482705e+01
FPE(n)	1.562198e-13	1.691108e-13	2.463009e-13	3.013104e-13

Таким образом, на основе проведенных тестов на основе информационных критериев, лучшим образом подходит модель с 1-м лагом.

Модель VAR(1):

```
varfit <- VAR(varmat, type = "trend", lag.max = 1)
summary(varfit)
```

VAR Estimation Results:

=====

Endogenous variables: d\_rates, d\_ln\_cpi, d\_ln\_gdp, d\_ln\_m1, d\_nc\_sdr, d\_brent

Deterministic variables: trend

Sample size: 96

Log Likelihood: 639.529

Roots of the characteristic polynomial:

0.4072 0.2429 0.1826 0.1826 0.06978 0.01633

Call:

VAR(y = varmat, type = "trend", lag.max = 1)

Estimation results for equation d\_rates:

=====

d\_rates = d\_rates.l1 + d\_ln\_cpi.l1 + d\_ln\_gdp.l1 + d\_ln\_m1.l1 + d\_nc\_sdr.l1 + d\_brent.l1 + trend

	Estimate	Std. Error	t value	Pr(> t )
d_rates.l1	1.490e-01	1.252e-01	1.190	0.237
d_ln_cpi.l1	-1.366e+01	1.259e+01	-1.084	0.281
d_ln_gdp.l1	3.519e+00	5.905e+00	0.596	0.553
d_ln_m1.l1	2.464e+00	1.762e+00	1.398	0.166
d_nc_sdr.l1	-1.762e-01	3.863e-01	-0.456	0.649
d_brent.l1	5.164e-03	4.798e-03	1.076	0.285
trend	-5.573e-04	1.073e-03	-0.520	0.605

Residual standard error: 0.435 on 89 degrees of freedom

Multiple R-Squared: 0.09237, Adjusted R-squared: 0.02099

F-statistic: 1.294 on 7 and 89 DF, p-value: 0.2625

Estimation results for equation d\_ln\_cpi:

=====

d\_ln\_cpi = d\_rates.l1 + d\_ln\_cpi.l1 + d\_ln\_gdp.l1 + d\_ln\_m1.l1 + d\_nc\_sdr.l1 + d\_brent.l1 + trend

	Estimate	Std. Error	t value	Pr(> t )
d_rates.l1	-1.549e-03	1.081e-03	-1.433	0.1554
d_ln_cpi.l1	5.476e-02	1.087e-01	0.504	0.6158
d_ln_gdp.l1	1.072e-01	5.098e-02	2.103	0.0383 *
d_ln_m1.l1	3.166e-02	1.522e-02	2.081	0.0403 *
d_nc_sdr.l1	-2.727e-03	3.335e-03	-0.818	0.4158
d_brent.l1	6.117e-05	4.142e-05	1.477	0.1433
trend	3.947e-05	9.260e-06	4.262	5.03e-05 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.003756 on 89 degrees of freedom

Multiple R-Squared: 0.4749, Adjusted R-squared: 0.4336

F-statistic: 11.5 on 7 and 89 DF, p-value: 2.575e-10

Estimation results for equation d\_ln\_gdp:

=====

d\_ln\_gdp = d\_rates.l1 + d\_ln\_cpi.l1 + d\_ln\_gdp.l1 + d\_ln\_m1.l1 + d\_nc\_sdr.l1 + d\_brent.l1 + trend

	Estimate	Std. Error	t value	Pr(> t )
d_rates.l1	5.248e-03	2.021e-03	2.596	0.0110 *
d_ln_cpi.l1	8.914e-02	2.033e-01	0.438	0.6621
d_ln_gdp.l1	1.708e-01	9.532e-02	1.792	0.0765 .
d_ln_m1.l1	6.762e-02	2.845e-02	2.377	0.0196 *
d_nc_sdr.l1	-1.612e-03	6.236e-03	-0.258	0.7967
d_brent.l1	1.595e-04	7.745e-05	2.059	0.0424 *
trend	4.120e-05	1.731e-05	2.379	0.0195 *

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.007022 on 89 degrees of freedom

Multiple R-Squared: 0.4124, Adjusted R-squared: 0.3662

F-statistic: 8.922 on 7 and 89 DF, p-value: 2.745e-08

Estimation results for equation d\_ln\_m1:

=====

d\_ln\_m1 = d\_rates.l1 + d\_ln\_cpi.l1 + d\_ln\_gdp.l1 + d\_ln\_m1.l1 + d\_nc\_sdr.l1 + d\_brent.l1 + trend

	Estimate	Std. Error	t value	Pr(> t )
d_rates.l1	1.545e-03	7.824e-03	0.197	0.8439
d_ln_cpi.l1	7.769e-01	7.870e-01	0.987	0.3263
d_ln_gdp.l1	6.349e-01	3.690e-01	1.721	0.0888 .
d_ln_m1.l1	-1.304e-01	1.101e-01	-1.185	0.2394
d_nc_sdr.l1	-1.577e-02	2.414e-02	-0.653	0.5153
d_brent.l1	-1.868e-04	2.998e-04	-0.623	0.5349
trend	2.498e-05	6.702e-05	0.373	0.7103

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02718 on 89 degrees of freedom

Multiple R-Squared: 0.09291, Adjusted R-squared: 0.02157

F-statistic: 1.302 on 7 and 89 DF, p-value: 0.2585

Estimation results for equation d\_nc\_sdr:

=====

d\_nc\_sdr = d\_rates.l1 + d\_ln\_cpi.l1 + d\_ln\_gdp.l1 + d\_ln\_m1.l1 + d\_nc\_sdr.l1 + d\_brent.l1 + trend

	Estimate	Std. Error	t value	Pr(> t )
d_rates.l1	0.0026781	0.0352130	0.076	0.940
d_ln_cpi.l1	0.9132715	3.5417786	0.258	0.797
d_ln_gdp.l1	1.0463219	1.6605843	0.630	0.530
d_ln_m1.l1	-0.4070788	0.4955845	-0.821	0.414
d_nc_sdr.l1	-0.0093864	0.1086361	-0.086	0.931
d_brent.l1	-0.0004502	0.0013492	-0.334	0.739
trend	-0.0001387	0.0003016	-0.460	0.647

Residual standard error: 0.1223 on 89 degrees of freedom  
Multiple R-Squared: 0.01311, Adjusted R-squared: -0.06451  
F-statistic: 0.1689 on 7 and 89 DF, p-value: 0.9908

Estimation results for equation d\_brent:

=====

d\_brent = d\_rates.l1 + d\_ln\_cpi.l1 + d\_ln\_gdp.l1 + d\_ln\_m1.l1 + d\_nc\_sdr.l1 + d\_brent.l1 + trend

	Estimate	Std. Error	t value	Pr(> t )
d_rates.l1	-2.843e+00	3.397e+00	-0.837	0.405
d_ln_cpi.l1	-1.511e+02	3.417e+02	-0.442	0.659
d_ln_gdp.l1	5.961e+01	1.602e+02	0.372	0.711
d_ln_m1.l1	5.107e+01	4.781e+01	1.068	0.288
d_nc_sdr.l1	-7.385e-01	1.048e+01	-0.070	0.944
d_brent.l1	1.455e-01	1.302e-01	1.118	0.267
trend	4.557e-03	2.910e-02	0.157	0.876

Residual standard error: 11.8 on 89 degrees of freedom  
Multiple R-Squared: 0.03501, Adjusted R-squared: -0.04089  
F-statistic: 0.4613 on 7 and 89 DF, p-value: 0.86

Covariance matrix of residuals:

	d_rates	d_ln_cpi	d_ln_gdp	d_ln_m1	d_nc_sdr	d_brent
d_rates	0.1887849	3.130e-04	6.703e-04	-2.163e-03	3.737e-03	2.45173
d_ln_cpi	0.0003130	1.378e-05	-5.458e-07	1.579e-05	1.604e-05	0.01696
d_ln_gdp	0.0006703	-5.458e-07	4.920e-05	2.651e-05	-7.841e-05	0.01272
d_ln_m1	-0.0021633	1.579e-05	2.651e-05	7.235e-04	-5.159e-06	-0.01703
d_nc_sdr	0.0037370	1.604e-05	-7.841e-05	-5.159e-06	1.490e-02	-0.19069
d_brent	2.4517289	1.696e-02	1.272e-02	-1.703e-02	-1.907e-01	139.28552

Correlation matrix of residuals:

	d_rates	d_ln_cpi	d_ln_gdp	d_ln_m1	d_nc_sdr	d_brent
d_rates	1.00000	0.19410	0.21994	-0.185101	0.070464	0.47812
d_ln_cpi	0.19410	1.00000	-0.02096	0.158181	0.035405	0.38708
d_ln_gdp	0.21994	-0.02096	1.00000	0.140488	-0.091580	0.15369
d_ln_m1	-0.18510	0.15818	0.14049	1.000000	-0.001571	-0.05363



```
d_nc_sdr  0.07046  0.03541 -0.09158 -0.001571  1.000000 -0.13238
d_brent   0.47812  0.38708  0.15369 -0.053630 -0.132375  1.00000
```

Проверим получившуюся модель VAR(1) на автокорреляцию с помощью обратных корней:

```
vars::roots(varfit)
```

```
[1] 0.40720098 0.24288983 0.18262686 0.18262686 0.06978198 0.01632764
```

Как видно из вышеприведенных значений обратные корни для остатков модели VAR(1) стационарны, т.к. получившиеся значения не превосходят по модулю 1.

Исходя из результатов теста Фишера значимыми получились 2 уравнения для 1-й разности логарифма CPI(d\_ln\_cpi)(P-value = 2.575e-10 ) и для 1-й разности логарифма GDP(d\_ln\_gdp)(P-value = 2.745e-08). Для теста Фишера нулевая гипотеза - незначимость модели в целом.

Проверим остатки каждого из уравнения модели VAR(1) на наличие автокорреляции с помощью теста Льюинга-Бокса:

```
Box.test(varfit$varresult$d_rates$residuals, type= "Ljung-Box")
```

Box-Ljung test

```
data: varfit$varresult$d_rates$residuals
X-squared = 0.12976, df = 1, p-value = 0.7187
```

```
Box.test(varfit$varresult$d_ln_cpi$residuals, type= "Ljung-Box")
```

Box-Ljung test

```
data: varfit$varresult$d_ln_cpi$residuals
X-squared = 1.6389, df = 1, p-value = 0.2005
```

```
Box.test(varfit$varresult$d_ln_gdp$residuals, type= "Ljung-Box")
```

Box-Ljung test

```
data: varfit$varresult$d_ln_gdp$residuals
X-squared = 0.21487, df = 1, p-value = 0.643
```

```
Box.test(varfit$varresult$d_ln_m1$residuals, type= "Ljung-Box")
```

Box-Ljung test

```
data: varfit$varresult$d_ln_m1$residuals
X-squared = 0.89527, df = 1, p-value = 0.3441
```

```
Box.test(varfit$varresult$d_nc_sdr$residuals, type= "Ljung-Box")
```

#### Box-Ljung test

```
data: varfit$varresult$d_nc_sdr$residuals  
X-squared = 0.016403, df = 1, p-value = 0.8981
```

```
Box.test(varfit$varresult$d_brent$residuals, type= "Ljung-Box")
```

#### Box-Ljung test

```
data: varfit$varresult$d_brent$residuals  
X-squared = 0.054194, df = 1, p-value = 0.8159
```

Таким образом в остатках 6-ти уравнений модели VAR(1) не отвергается нулевая гипотеза на 5% уровне значимости об отсутствии автокорреляции.

Проведем также Тест Харке — Бера на нормальность остатков, где  $H_0$  - гипотеза о нормальности ошибок распределений:

```
normality.test(varfit)
```

```
$JB
```

#### JB-Test (multivariate)

```
data: Residuals of VAR object varfit  
Chi-squared = 19429, df = 12, p-value < 2.2e-16
```

```
$Skewness
```

#### Skewness only (multivariate)

```
data: Residuals of VAR object varfit  
Chi-squared = 1042, df = 6, p-value < 2.2e-16
```

```
$Kurtosis
```

#### Kurtosis only (multivariate)

```
data: Residuals of VAR object varfit  
Chi-squared = 18387, df = 6, p-value < 2.2e-16
```

Отвергается на 5% уровне значимости гипотеза о нормальности остатков в модели VAR(2).

## 4. Тест на причинность по Грейнджеру

Проведем тест на причинность по Грейнджеру для того, чтобы лучше специфицировать модель.  $H_0$ : коэффициент при лагах объясняющей переменной равен 0, т.е. нет взаимосвязи между изменениями двух временных рядов. Результаты теста приведены ниже:

*# Для ставки d\_rates:*

```
grangertest(d_rates~d_ln_cpi, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1: d\_rates ~ Lags(d\_rates, 1:1) + Lags(d\_ln\_cpi, 1:1)

Model 2: d\_rates ~ Lags(d\_rates, 1:1)

	Res.Df	Df	F	Pr(>F)
1	93			
2	94	-1	0.0019	0.9652

```
grangertest(d_rates~d_ln_cpi, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1: d\_rates ~ Lags(d\_rates, 1:1) + Lags(d\_ln\_cpi, 1:1)

Model 2: d\_rates ~ Lags(d\_rates, 1:1)

	Res.Df	Df	F	Pr(>F)
1	93			
2	94	-1	0.0019	0.9652

```
grangertest(d_rates~d_ln_gdp, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1: d\_rates ~ Lags(d\_rates, 1:1) + Lags(d\_ln\_gdp, 1:1)

Model 2: d\_rates ~ Lags(d\_rates, 1:1)

	Res.Df	Df	F	Pr(>F)
1	93			
2	94	-1	1.4079	0.2384

```
grangertest(d_rates~d_ln_m1, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1: d\_rates ~ Lags(d\_rates, 1:1) + Lags(d\_ln\_m1, 1:1)

Model 2: d\_rates ~ Lags(d\_rates, 1:1)

	Res.Df	Df	F	Pr(>F)
1	93			
2	94	-1	2.7553	0.1003

```
grangertest(d_rates~d_brent, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1: d\_rates ~ Lags(d\_rates, 1:1) + Lags(d\_brent, 1:1)

```
Model 2: d_rates ~ Lags(d_rates, 1:1)
      Res.Df Df      F Pr(>F)
1         93
2         94 -1 0.9486 0.3326
```

*# Для d\_ln\_cpi:*

```
grangertest(d_ln_cpi~d_rates, order = 1, data = as.data.frame(varmat))
```

Granger causality test

```
Model 1: d_ln_cpi ~ Lags(d_ln_cpi, 1:1) + Lags(d_rates, 1:1)
Model 2: d_ln_cpi ~ Lags(d_ln_cpi, 1:1)
      Res.Df Df      F Pr(>F)
1         93
2         94 -1 0.018 0.8934
```

```
grangertest(d_ln_cpi~d_ln_gdp, order = 1, data = as.data.frame(varmat))
```

Granger causality test

```
Model 1: d_ln_cpi ~ Lags(d_ln_cpi, 1:1) + Lags(d_ln_gdp, 1:1)
Model 2: d_ln_cpi ~ Lags(d_ln_cpi, 1:1)
      Res.Df Df      F Pr(>F)
1         93
2         94 -1 2.962 0.08857 .
```

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

```
grangertest(d_ln_cpi~d_ln_m1, order = 1, data = as.data.frame(varmat))
```

Granger causality test

```
Model 1: d_ln_cpi ~ Lags(d_ln_cpi, 1:1) + Lags(d_ln_m1, 1:1)
Model 2: d_ln_cpi ~ Lags(d_ln_cpi, 1:1)
      Res.Df Df      F Pr(>F)
1         93
2         94 -1 2.2032 0.1411
```

```
grangertest(d_ln_cpi~d_nc_sdr, order = 1, data = as.data.frame(varmat))
```

Granger causality test

```
Model 1: d_ln_cpi ~ Lags(d_ln_cpi, 1:1) + Lags(d_nc_sdr, 1:1)
Model 2: d_ln_cpi ~ Lags(d_ln_cpi, 1:1)
      Res.Df Df      F Pr(>F)
1         93
2         94 -1 0.4891 0.4861
```

```
grangertest(d_ln_cpi~d_brent, order = 1, data = as.data.frame(varmat))
```

Granger causality test

```
Model 1: d_ln_cpi ~ Lags(d_ln_cpi, 1:1) + Lags(d_brent, 1:1)
Model 2: d_ln_cpi ~ Lags(d_ln_cpi, 1:1)
```

```

    Res.Df Df      F    Pr(>F)
1      93
2      94 -1 3.9722 0.04919 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

# Для ставки d_ln_gdp:
grangertest(d_ln_gdp~d_rates, order = 1, data = as.data.frame(varmat))

Granger causality test

Model 1: d_ln_gdp ~ Lags(d_ln_gdp, 1:1) + Lags(d_rates, 1:1)
Model 2: d_ln_gdp ~ Lags(d_ln_gdp, 1:1)
    Res.Df Df      F    Pr(>F)
1      93
2      94 -1 15.046 0.0001956 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

grangertest(d_ln_gdp~d_ln_cpi, order = 1, data = as.data.frame(varmat))

Granger causality test

Model 1: d_ln_gdp ~ Lags(d_ln_gdp, 1:1) + Lags(d_ln_cpi, 1:1)
Model 2: d_ln_gdp ~ Lags(d_ln_gdp, 1:1)
    Res.Df Df      F    Pr(>F)
1      93
2      94 -1 3.3316 0.07117 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

grangertest(d_ln_gdp~d_ln_m1, order = 1, data = as.data.frame(varmat))

Granger causality test

Model 1: d_ln_gdp ~ Lags(d_ln_gdp, 1:1) + Lags(d_ln_m1, 1:1)
Model 2: d_ln_gdp ~ Lags(d_ln_gdp, 1:1)
    Res.Df Df      F    Pr(>F)
1      93
2      94 -1 1.1029 0.2964

grangertest(d_ln_gdp~d_nc_sdr, order = 1, data = as.data.frame(varmat))

Granger causality test

Model 1: d_ln_gdp ~ Lags(d_ln_gdp, 1:1) + Lags(d_nc_sdr, 1:1)
Model 2: d_ln_gdp ~ Lags(d_ln_gdp, 1:1)
    Res.Df Df      F    Pr(>F)
1      93
2      94 -1 9e-04 0.9758

grangertest(d_ln_gdp~d_brent, order = 1, data = as.data.frame(varmat))

```

Granger causality test

Model 1: d\_ln\_gdp ~ Lags(d\_ln\_gdp, 1:1) + Lags(d\_brent, 1:1)

Model 2: d\_ln\_gdp ~ Lags(d\_ln\_gdp, 1:1)

	Res.Df	Df	F	Pr(>F)
1	93			
2	94	-1	14.182	0.0002907 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

*# Для ставки d\_ln\_m1:*

```
grangertest(d_ln_m1~d_rates, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1: d\_ln\_m1 ~ Lags(d\_ln\_m1, 1:1) + Lags(d\_rates, 1:1)

Model 2: d\_ln\_m1 ~ Lags(d\_ln\_m1, 1:1)

	Res.Df	Df	F	Pr(>F)
1	93			
2	94	-1	0.9026	0.3446

```
grangertest(d_ln_m1~d_ln_cpi, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1: d\_ln\_m1 ~ Lags(d\_ln\_m1, 1:1) + Lags(d\_ln\_cpi, 1:1)

Model 2: d\_ln\_m1 ~ Lags(d\_ln\_m1, 1:1)

	Res.Df	Df	F	Pr(>F)
1	93			
2	94	-1	0.4675	0.4959

```
grangertest(d_ln_m1~d_ln_gdp, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1: d\_ln\_m1 ~ Lags(d\_ln\_m1, 1:1) + Lags(d\_ln\_gdp, 1:1)

Model 2: d\_ln\_m1 ~ Lags(d\_ln\_m1, 1:1)

	Res.Df	Df	F	Pr(>F)
1	93			
2	94	-1	1.7954	0.1835

```
grangertest(d_ln_m1~d_nc_sdr, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1: d\_ln\_m1 ~ Lags(d\_ln\_m1, 1:1) + Lags(d\_nc\_sdr, 1:1)

Model 2: d\_ln\_m1 ~ Lags(d\_ln\_m1, 1:1)

	Res.Df	Df	F	Pr(>F)
1	93			
2	94	-1	0.1514	0.6981

```
grangertest(d_ln_m1~d_brent, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1:  $d\_ln\_m1 \sim Lags(d\_ln\_m1, 1:1) + Lags(d\_brent, 1:1)$

Model 2:  $d\_ln\_m1 \sim Lags(d\_ln\_m1, 1:1)$

	Res.Df	Df	F	Pr(>F)
1	93			
2	94	-1	0.0028	0.9578

*# Для ставки d\_nc\_sdr:*

```
grangertest(d_nc_sdr~d_rates, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1:  $d\_nc\_sdr \sim Lags(d\_nc\_sdr, 1:1) + Lags(d\_rates, 1:1)$

Model 2:  $d\_nc\_sdr \sim Lags(d\_nc\_sdr, 1:1)$

	Res.Df	Df	F	Pr(>F)
1	93			
2	94	-1	0.0551	0.815

```
grangertest(d_nc_sdr~d_ln_cpi, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1:  $d\_nc\_sdr \sim Lags(d\_nc\_sdr, 1:1) + Lags(d\_ln\_cpi, 1:1)$

Model 2:  $d\_nc\_sdr \sim Lags(d\_nc\_sdr, 1:1)$

	Res.Df	Df	F	Pr(>F)
1	93			
2	94	-1	0.6032	0.4393

```
grangertest(d_nc_sdr~d_ln_gdp, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1:  $d\_nc\_sdr \sim Lags(d\_nc\_sdr, 1:1) + Lags(d\_ln\_gdp, 1:1)$

Model 2:  $d\_nc\_sdr \sim Lags(d\_nc\_sdr, 1:1)$

	Res.Df	Df	F	Pr(>F)
1	93			
2	94	-1	0.7484	0.3892

```
grangertest(d_nc_sdr~d_ln_m1, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1:  $d\_nc\_sdr \sim Lags(d\_nc\_sdr, 1:1) + Lags(d\_ln\_m1, 1:1)$

Model 2:  $d\_nc\_sdr \sim Lags(d\_nc\_sdr, 1:1)$

	Res.Df	Df	F	Pr(>F)
1	93			
2	94	-1	0.2283	0.6339

```
grangertest(d_nc_sdr~d_brent, order = 1, data = as.data.frame(varmat))
```

Granger causality test

Model 1:  $d\_nc\_sdr \sim Lags(d\_nc\_sdr, 1:1) + Lags(d\_brent, 1:1)$

```
Model 2: d_nc_sdr ~ Lags(d_nc_sdr, 1:1)
  Res.Df Df      F Pr(>F)
1      93
2      94 -1 0.0034 0.9534
```

*# Для ставки d\_brent:*

```
grangertest(d_brent~d_rates, order = 1, data = as.data.frame(varmat))
```

Granger causality test

```
Model 1: d_brent ~ Lags(d_brent, 1:1) + Lags(d_rates, 1:1)
Model 2: d_brent ~ Lags(d_brent, 1:1)
  Res.Df Df      F Pr(>F)
1      93
2      94 -1 0.9668 0.328
```

```
grangertest(d_brent~d_ln_cpi, order = 1, data = as.data.frame(varmat))
```

Granger causality test

```
Model 1: d_brent ~ Lags(d_brent, 1:1) + Lags(d_ln_cpi, 1:1)
Model 2: d_brent ~ Lags(d_brent, 1:1)
  Res.Df Df      F Pr(>F)
1      93
2      94 -1 0.2054 0.6514
```

```
grangertest(d_brent~d_ln_gdp, order = 1, data = as.data.frame(varmat))
```

Granger causality test

```
Model 1: d_brent ~ Lags(d_brent, 1:1) + Lags(d_ln_gdp, 1:1)
Model 2: d_brent ~ Lags(d_brent, 1:1)
  Res.Df Df      F Pr(>F)
1      93
2      94 -1 0.071 0.7905
```

```
grangertest(d_brent~d_ln_m1, order = 1, data = as.data.frame(varmat))
```

Granger causality test

```
Model 1: d_brent ~ Lags(d_brent, 1:1) + Lags(d_ln_m1, 1:1)
Model 2: d_brent ~ Lags(d_brent, 1:1)
  Res.Df Df      F Pr(>F)
1      93
2      94 -1 1.4866 0.2258
```

```
grangertest(d_brent~d_nc_sdr, order = 1, data = as.data.frame(varmat))
```

Granger causality test

```
Model 1: d_brent ~ Lags(d_brent, 1:1) + Lags(d_nc_sdr, 1:1)
Model 2: d_brent ~ Lags(d_brent, 1:1)
  Res.Df Df      F Pr(>F)
```



1	93
2	94 -1 0.0532 0.8181

Вычисленные значения p-value показывают:

- лаги d\_ln\_gdp помогают предсказать значения d\_ln\_cpi на 10% уровне значимости(p-value = 0.08857)
- лаги d\_brent помогают объяснить изменение значений d\_ln\_cpi на 5% уровне значимости(p-value = 0.04919)
- лаги d\_rates помогают объяснить значения d\_ln\_gdp на 5% уровне значимости(p-value = 0,0001956)
- лаги d\_ln\_cpi помогают объяснить d\_ln\_gdp на 10% уровне значимости(p-value = )
- лаги d\_brent помогают объяснить изменение значения ряда d\_ln\_gdp на 5% уровне значимости(p-value = 0.0002907)
- Других причинно-следственных связей на адекватном уровне значимости не было установлено.

Модель VAR для лучшей спецификации можно изменить следующим образом:

1. Удалим из модели d\_ln\_m1, d\_nc\_sdr
2. Оставим d\_ln\_gdp, d\_ln\_cpi в эндогенных факторах
3. Добавим d\_rates, d\_brent в экзогенные факторы

Определим количество лагов для того, чтобы лучше оценить модель VAR:

```
varmat2 <- as.matrix(cbind(d_rates, d_ln_cpi, d_ln_gdp, d_brent))
VARselect(varmat2, lag.max = 4, type= "trend")

$selection
AIC(n)  HQ(n)  SC(n) FPE(n)
      2      1      1      2

$criteria
              1              2              3              4
AIC(n) -1.812051e+01 -1.818413e+01 -1.805356e+01 -1.814184e+01
HQ(n)  -1.790060e+01 -1.778829e+01 -1.748179e+01 -1.739414e+01
SC(n)  -1.757587e+01 -1.720377e+01 -1.663749e+01 -1.629005e+01
FPE(n)  1.350644e-08  1.269951e-08  1.454246e-08  1.343746e-08
```

В этот раз, нельзя так однозначно сказать, какой лучше взять порядок лага. Поэтому руководствуясь принципом, что AIC при малых выборках дает лучший результат, чем HQ, то возьмем лаг 2.

```
exog <- as.matrix(cbind(d_rates, d_brent))
endog <- as.matrix(cbind(d_ln_cpi, d_ln_gdp))
varfit2 <- VAR(endog, type = "const", lag.max = 2, exogen = exog)
summary(varfit2)
```

# VAR Estimation Results:

=====

Endogenous variables: d\_ln\_cpi, d\_ln\_gdp

Deterministic variables: const

Sample size: 96

Log Likelihood: 757.606

Roots of the characteristic polynomial:

0.316 0.1468

Call:

VAR(y = endog, type = "const", exogen = exog, lag.max = 2)

## Estimation results for equation d\_ln\_cpi:

=====

d\_ln\_cpi = d\_ln\_cpi.l1 + d\_ln\_gdp.l1 + const + d\_rates + d\_brent

	Estimate	Std. Error	t value	Pr(> t )
d_ln_cpi.l1	-0.0872808	0.0923142	-0.945	0.346920
d_ln_gdp.l1	0.0635845	0.0410500	1.549	0.124865
const	0.0035911	0.0004926	7.289	1.1e-10 ***
d_rates	0.0007185	0.0008632	0.832	0.407388
d_brent	0.0001182	0.0000320	3.692	0.000379 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.003169 on 91 degrees of freedom

Multiple R-Squared: 0.2285, Adjusted R-squared: 0.1946

F-statistic: 6.74 on 4 and 91 DF, p-value: 8.5e-05

## Estimation results for equation d\_ln\_gdp:

=====

d\_ln\_gdp = d\_ln\_cpi.l1 + d\_ln\_gdp.l1 + const + d\_rates + d\_brent

	Estimate	Std. Error	t value	Pr(> t )
d_ln_cpi.l1	3.774e-01	2.135e-01	1.768	0.08045 .
d_ln_gdp.l1	2.565e-01	9.494e-02	2.702	0.00822 **
const	1.741e-03	1.139e-03	1.528	0.12997
d_rates	5.120e-03	1.996e-03	2.564	0.01197 *
d_brent	1.057e-05	7.401e-05	0.143	0.88676

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.00733 on 91 degrees of freedom

Multiple R-Squared: 0.2064, Adjusted R-squared: 0.1715

F-statistic: 5.918 on 4 and 91 DF, p-value: 0.0002806

Covariance matrix of residuals:

```
      d_ln_cpi  d_ln_gdp
d_ln_cpi 1.005e-05 -2.569e-06
d_ln_gdp -2.569e-06  5.373e-05
```

Correlation matrix of residuals:

```
      d_ln_cpi d_ln_gdp
d_ln_cpi  1.0000 -0.1106
d_ln_gdp -0.1106  1.0000
```

Проверим получившуюся модель VAR(1) на автокорреляцию с помощью обратных корней:

```
vars::roots(varfit2)
```

```
[1] 0.3160404 0.1467840
```

Как видно из вышеприведенных значений обратные корни для остатков модели VAR(1) стационарны, т.к. получившиеся значения не превосходят по модулю 1.

Исходя из результатов теста Фишера значимыми получились все уравнения в модели:

- для 1-й разности логарифма CPI(d\_ln\_cpi)(P-value = 8.5e-05 )
- для 1-й разности логарифма GDP(d\_ln\_gdp)(P-value = 0.0002806)
- для теста Фишера нулевая гипотеза - незначимость модели в целом.

Проверим остатки каждого из уравнения модели VAR(1) на наличие автокорреляции с помощью теста Льюинга-Бокса:

```
Box.test(varfit2$varresult$d_ln_cpi$residuals, type= "Ljung-Box")
```

Box-Ljung test

```
data: varfit2$varresult$d_ln_cpi$residuals
X-squared = 0.78391, df = 1, p-value = 0.3759
```

```
Box.test(varfit2$varresult$d_ln_gdp$residuals, type= "Ljung-Box")
```

Box-Ljung test

```
data: varfit2$varresult$d_ln_gdp$residuals
X-squared = 1.2819, df = 1, p-value = 0.2575
```

Таким образом, в остатках 6-ти уравнений модели VAR(1) не отвергается нулевая гипотеза на 5% уровне значимости об отсутствии автокорреляции.

Проведем также Тест Харке — Бера на нормальность остатков, где  $H_0$  - гипотеза о нормальности ошибок распределений:

```
normality.test(varfit2)
```

```
$JB
```

```
JB-Test (multivariate)
```

```
data: Residuals of VAR object varfit2
```

```
Chi-squared = 367.23, df = 4, p-value < 2.2e-16
```

```
$Skewness
```

```
Skewness only (multivariate)
```

```
data: Residuals of VAR object varfit2
```

```
Chi-squared = 57.648, df = 2, p-value = 3.033e-13
```

```
$Kurtosis
```

```
Kurtosis only (multivariate)
```

```
data: Residuals of VAR object varfit2
```

```
Chi-squared = 309.58, df = 2, p-value < 2.2e-16
```

Таким образом, отвергается на 5% уровне значимости гипотеза о нормальности остатков в модели VAR(2).


Импульсивные отклики:

*# Здесь может быть понадобится в консоли нажать Enter, чтобы график отобразился*

```
impresp <- irf(varfit2)
```


```
plot(impresp)
```

### Orthogonal Impulse Response from d\_ln\_cpi



95 % Bootstrap CI, 100 runs


### Orthogonal Impulse Response from d\_ln\_gdp



95 % Bootstrap CI, 100 runs

Разложение дисперсии ошибок:

```
plot(fevd(varfit2))
```




Таким образом ряды `d_ln_cpi` и `d_ln_gdp` реагируют в основном на свои собственные шоки, возникающие в лагах до 10-го порядка.


## 5. Тест Ингла-Грейнджера на коинтеграцию. Построение моделей ЕСМ.

Для начало построим парные графики первоначальных рядов, для того, чтобы визуально убедиться в наличии коинтеграции между рядами:

```
zoo::plot.zoo(ln_cpi)
```




```
zoo::plot.zoo(ln_gdp)
```




```
zoo::plot.zoo(ln_m1)
```







```
zoo::plot.zoo(brent)
```



```
zoo::plot.zoo(rates)
```



```
zoo::plot.zoo(nc_sdr)
```



Проведем двухшаговую процедуру Ингла-Грейнджера:

Шаг 1. Определение порядка интегрируемости

Из пункта 1 мы определили, что все ряды  $\sim I(1)$

Шаг 2б. Коинтеграционный вектор неизвестен.

Сначала строится вспомогательная регрессия вида:

$$y_t = \alpha + \beta x_t + \epsilon_t$$

Затем сохраняются из нее остатки, и на основе ее рассчитывается вспомогательная регрессию и тестируется гипотеза  $H_0: \rho = 0$ , т.е. ряд  $e_t$  принадлежит к классу DS и коинтеграции нет. В этом тесте используются критические точки МакКиннона.

```
coint <- function(x){
  d <- as.matrix(x)
  n <- length(colnames(x))
  m <- combn(n, 2) # Число возможных комбинаций попарных
  col_m <- dim(m)[2]
  result <- matrix(NA, nrow= col_m, ncol = 5)
  colnames(result) <- c("Response", "Input", "no trend", "linear trend", "quadratic trend")
  for (i in 1:col_m){
    Var_1 <- m[1, i]
    Var_2 <- m[2, i]
```

```

    res <- (coint.test(d[,Var_1], d[,Var_2], nlag = 4, output = F))
    result[i,1]<-colnames(x)[Var_1]
    result[i,2]<-colnames(x)[Var_2]
    result[i,3]<-toString(res[1,"p.value"])
    result[i,4]<-toString(res[2,"p.value"])
    result[i,5]<-toString(res[3,"p.value"])
  }
  return(result)
}

```

Создаем матрицу с нашими всеми первоначальными рядами и проводим попарный коинтеграционный тест Ингла-Грейнджера:

```

dt2 <- as.matrix(cbind(rates, ln_gdp, ln_m1, brent, ln_cpi, nc_sdr))
res1 <- coint(dt2)

```

Получаем следующую таблицу с результатами:

```
pander(res1)
```

Response	Input	no trend	linear trend	quadratic trend
rates	ln_gdp	0.0184649013276559	0.1	0.1
rates	ln_m1	0.1	0.1	0.1
rates	brent	0.1	0.1	0.1
rates	ln_cpi	0.0338955027664035	0.1	0.1
rates	nc_sdr	0.1	0.1	0.1
ln_gdp	ln_m1	0.1	0.1	0.1
ln_gdp	brent	0.1	0.1	0.1
ln_gdp	ln_cpi	0.0763217907972676	0.1	0.1
ln_gdp	nc_sdr	0.1	0.1	0.0630514542359205
ln_m1	brent	0.1	0.1	0.1
ln_m1	ln_cpi	0.1	0.1	0.1
ln_m1	nc_sdr	0.1	0.1	0.1
brent	ln_cpi	0.1	0.1	0.1
brent	nc_sdr	0.1	0.1	0.1
ln_cpi	nc_sdr	0.1	0.1	0.1

Составим аналогичную таблицу повторно, т.к. при небольших выборках, тест м.б. чувствителен от того, в каком порядке стоят попарно тестируемые ряды. Таким образом, составим матрицу, где бы столбцы шли в обратном порядке.

```

dt2 <- as.matrix(cbind(nc_sdr, ln_cpi, brent, ln_m1, ln_gdp, rates))
res2 <- coint(dt2)

```

```
pander(res2)
```

Response	Input	no trend	linear trend	quadratic trend
----------	-------	----------	--------------	-----------------

nc_sdr	ln_cpi	0.1	0.1	0.1
nc_sdr	brent	0.1	0.1	0.1
nc_sdr	ln_m1	0.0732535740288688	0.1	0.1
nc_sdr	ln_gdp	0.1	0.1	0.1
nc_sdr	rates	0.1	0.1	0.1
ln_cpi	brent	0.1	0.1	0.1
ln_cpi	ln_m1	0.1	0.1	0.1
ln_cpi	ln_gdp	0.0808120557540931	0.1	0.1
ln_cpi	rates	0.1	0.1	0.1
brent	ln_m1	0.1	0.1	0.1
brent	ln_gdp	0.1	0.1	0.1
brent	rates	0.1	0.1	0.1
ln_m1	ln_gdp	0.1	0.1	0.1
ln_m1	rates	0.1	0.1	0.1
ln_gdp	rates	0.0681299785700403	0.1	0.1

Из приведенных таблиц res1 и res2 можно сказать, что вероятней всего существует с 10% уровнем значимости коинтеграция между рядами ln\_gdp и rates(т.к. показано в первом случае 0.018, а во втором 0.068) и между ln\_cpi и ln\_gdp(в первом случае - 0.076, во втором - 0.08). Поскольку эти ряды приводятся к стационарному виду в результате взятия первой разности, то обе коинтеграции CI(1,1).

Построим модели ЕСМ для для этих пар.

Для начала оценим по МНК долгосрочные соотношения между этими рядами:

$$\ln\_gdp(t) = b * rates(t)$$

$$\ln\_cpi(t) = b * \ln\_gdp(t)$$

Возьмем остатки из этих моделей и проверим их на стационарность с помощью теста ADF:

```
mod1 <- lm(ln_gdp~rates-1)
mod2 <- lm(ln_cpi~ln_gdp-1)
```

```
summary(mod1)
```

Call:

```
lm(formula = ln_gdp ~ rates - 1)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-8.2709  0.2285  4.4753 12.7392 16.0703
```

Coefficients:

```
      Estimate Std. Error t value Pr(>|t|)
```

```

rates    3.2959      0.2857    11.54    <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```

Residual standard error: 8.673 on 97 degrees of freedom
Multiple R-squared:  0.5784,    Adjusted R-squared:  0.574
F-statistic: 133.1 on 1 and 97 DF,  p-value: < 2.2e-16

```

```
summary(mod2)
```

```

Call:
lm(formula = ln_cpi ~ ln_gdp - 1)

```

```

Residuals:
      Min       1Q   Median       3Q      Max
-0.117405 -0.076388 -0.003803  0.073690  0.105592

```

```

Coefficients:
      Estimate Std. Error t value Pr(>|t|)
ln_gdp 0.3420072  0.0005487   623.3  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```

Residual standard error: 0.07218 on 97 degrees of freedom
Multiple R-squared:  0.9998,    Adjusted R-squared:  0.9997
F-statistic: 3.885e+05 on 1 and 97 DF,  p-value: < 2.2e-16

```

```

test1 <- (ur.df(mod1$residuals, type = "none"))
test2 <- (ur.df(mod2$residuals, type = "none"))

```

```
summary(test1)
```

```

#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

```

```
Test regression none
```

```

Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)

```

```

Residuals:
      Min       1Q   Median       3Q      Max
-4.1782 -0.6215  0.1849  0.6473  4.9465

```

```

Coefficients:
      Estimate Std. Error t value Pr(>|t|)
z.lag.1    -0.004747   0.017394  -0.273   0.7855
z.diff.lag  0.193728   0.102736   1.886   0.0624 .

```

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 1.435 on 94 degrees of freedom
Multiple R-squared:  0.03648,    Adjusted R-squared:  0.01598
F-statistic:  1.78 on 2 and 94 DF,  p-value: 0.1743
```

Value of test-statistic is: -0.2729

Critical values for test statistics:

```
      1pct   5pct  10pct
tau1 -2.6  -1.95 -1.61
```

`summary(test2)`

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression none

Call:

```
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-0.006810 -0.001438  0.001152  0.004635  0.014377
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
z.lag.1      -0.004107   0.007137  -0.576   0.566
z.diff.lag    0.124475   0.102158   1.218   0.226
```

```
Residual standard error: 0.004946 on 94 degrees of freedom
Multiple R-squared:  0.01919,    Adjusted R-squared:  -0.001679
F-statistic: 0.9196 on 2 and 94 DF,  p-value: 0.4023
```

Value of test-statistic is: -0.5755

Critical values for test statistics:

```
      1pct   5pct  10pct
tau1 -2.6  -1.95 -1.61
```

Обе тестовых значения получились меньше тестовой статистики, что говорит о том, что нулевая гипотеза о наличии в остатках единичного корня отвергается. Таким образом получается, что возможна коинтеграция  $CI(1,1)$  с коинтегрирующими векторами  $(1, -3.2959)$  для пары  $(\ln\_gdp, rates)$  и  $(1, 0.1174)$  для пары  $(\ln\_cpi, \ln\_gdp)$



Построим модель ECM вида:

$$\Delta y_t = \mu + \phi \Delta x_t + \gamma(y_{t-1} - \beta x_{t-1}) + \epsilon_t$$

Для модели  $d\_rates \sim d\_ln\_gdp$  мы исключим константу из вспомогательной модели, т.к. в ряде  $rates$  не присутствует тренд в отличие от  $ln\_gdp$ . В этом можно удостовериться с помощью проведенного ранее ADF теста. Также проверим обе модели на нормальность остатков модели, что является очень важным условием при оценивании методом МНК.

```
# ECM модель для пары (ln_gdp, rates)
```

```
uhat1 <- (stats::lag(ln_gdp, k= 1) - as.numeric(mod1$coefficients)*stats::lag(rates, k= 1))
```

```
uhat2 <- (stats::lag(ln_cpi, k= 1) - as.numeric(mod1$coefficients)*stats::lag(ln_gdp, k= 1))
```

```
ecm1_1 <- lm(d_ln_gdp ~ d_rates + uhat1)
```

```
ecm1_2 <- lm(d_rates ~ d_ln_gdp + uhat1-1)
```

```
(summary(ecm1_1))
```

Call:

```
lm(formula = d_ln_gdp ~ d_rates + uhat1)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.046718	-0.002926	0.000355	0.004580	0.018589

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	0.0041662	0.0010253	4.063	0.000100 ***
d_rates	0.0061576	0.0017967	3.427	0.000906 ***
uhat1	-0.0000157	0.0001190	-0.132	0.895309

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.007624 on 94 degrees of freedom

Multiple R-squared: 0.1131, Adjusted R-squared: 0.09426

F-statistic: 5.995 on 2 and 94 DF, p-value: 0.003544

```
(summary(ecm1_2))
```

Call:

```
lm(formula = d_rates ~ d_ln_gdp + uhat1 - 1)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-1.33308	-0.24893	0.03867	0.18107	1.18600

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
--	----------	------------	---------	----------

```
d_ln_gdp 14.99036    4.95993    3.022    0.00322 **
uhat1    -0.01244    0.00503   -2.473    0.01518 *
```

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4162 on 95 degrees of freedom  
Multiple R-squared: 0.1151, Adjusted R-squared: 0.09646  
F-statistic: 6.178 on 2 and 95 DF, p-value: 0.003004

```
shapiro.test(as.numeric(ecm1_1$residuals)) # Тест на нормальность остатков
```

Shapiro-Wilk normality test

```
data:  as.numeric(ecm1_1$residuals)
W = 0.82225, p-value = 1.898e-09
```

```
shapiro.test(as.numeric(ecm1_2$residuals))
```

Shapiro-Wilk normality test

```
data:  as.numeric(ecm1_2$residuals)
W = 0.9544, p-value = 0.001991
```

Исходя из результатов из первой модели, коэффициент uhat1 незначим на 5% уровне значимости, а во второй - значим на 5% уровне значимости и отрицателен => имеет место быть только односторонняя коррекция rates относительно ln\_gdp, причем скорость коррекции составляет 1,2%. К сожалению, для остатков обеих моделей отвергается нормальность остатков модели на 5% уровне значимости.

В модель ЕСМ константу оставляем для рядов(ln\_cpi, ln\_gdp), т.к. при проверке на стационарность с помощью теста ADF, был выявлен тренд в обоих рядах.

```
# ЕСМ модель для пары (ln_cpi, ln_gdp)
ecm2_1 <- lm(d_ln_cpi ~ d_ln_gdp + uhat2)
ecm2_2 <- lm(d_ln_gdp ~ d_ln_cpi + uhat2)
```

```
(summary(ecm2_1))
```

Call:

```
lm(formula = d_ln_cpi ~ d_ln_gdp + uhat2)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.0073644	-0.0025236	-0.0006039	0.0022397	0.0098548

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	5.697e-03	6.677e-02	0.085	0.932
d_ln_gdp	1.454e-02	4.541e-02	0.320	0.750
uhat2	5.581e-05	1.701e-03	0.033	0.974

Residual standard error: 0.003552 on 94 degrees of freedom  
Multiple R-squared: 0.00109, Adjusted R-squared: -0.02016  
F-statistic: 0.05129 on 2 and 94 DF, p-value: 0.95

```
(summary(ecm2_2))
```

Call:

```
lm(formula = d_ln_gdp ~ d_ln_cpi + uhat2)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.048969	-0.002953	0.000091	0.004473	0.016812

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	-0.120669	0.151055	-0.799	0.426
d_ln_cpi	0.074934	0.234008	0.320	0.750
uhat2	-0.003161	0.003848	-0.822	0.413

Residual standard error: 0.008063 on 94 degrees of freedom  
Multiple R-squared: 0.008199, Adjusted R-squared: -0.0129  
F-statistic: 0.3886 on 2 and 94 DF, p-value: 0.6791

```
shapiro.test(as.numeric(ecm2_1$residuals)) # Тест на нормальность остатков
```

Shapiro-Wilk normality test

```
data: as.numeric(ecm2_1$residuals)  
W = 0.97917, p-value = 0.1263
```

```
shapiro.test(as.numeric(ecm2_2$residuals))
```

Shapiro-Wilk normality test

```
data: as.numeric(ecm2_2$residuals)  
W = 0.81968, p-value = 1.565e-09
```

Коэффициенты при uhat2 в обеих моделях оказались незначимы на 5% уровне значимости => коинтеграции нет

## 6. Модель VECM и тест Йохансена

Составим модель VECM для первоначальных нестационарных рядов. Для это создадим матрицу, объединяющую все ряды и выберем порядком лага для нашей VAR.

Максимальный лаг, как и прежде - 4, т.к. данные квартальные:

```
varmat3 <- as.matrix(cbind(rates, ln_cpi, ln_gdp, ln_m1, nc_sdr, brent))  
VARselect(varmat3, lag.max = 4, type= "trend")
```

```

$selection
AIC(n)  HQ(n)  SC(n) FPE(n)
      1      1      1      1

$criteria
              1              2              3              4
AIC(n) -2.999746e+01 -2.995573e+01 -2.992391e+01 -2.961480e+01
HQ(n)  -2.953845e+01 -2.910329e+01 -2.867803e+01 -2.797549e+01
SC(n)  -2.886110e+01 -2.784534e+01 -2.683949e+01 -2.555636e+01
FPE(n)  9.396971e-14  9.886439e-14  1.044525e-13  1.487972e-13

```

Все информационные критерии говорят о том, что следует выбрать VAR(1). Построим ее:

```

varfit3 <- VAR(varmat3, type = "trend", lag.max = 1)
summary(varfit3)

```

#### VAR Estimation Results:

=====

Endogenous variables: rates, ln\_cpi, ln\_gdp, ln\_m1, nc\_sdr, brent

Deterministic variables: trend

Sample size: 97

Log Likelihood: 673.534

Roots of the characteristic polynomial:

1 0.9435 0.9435 0.8367 0.7275 0.7275

Call:

VAR(y = varmat3, type = "trend", lag.max = 1)

#### Estimation results for equation rates:

=====

rates = rates.l1 + ln\_cpi.l1 + ln\_gdp.l1 + ln\_m1.l1 + nc\_sdr.l1 + brent.l1 + trend

	Estimate	Std. Error	t value	Pr(> t )
rates.l1	0.792466	0.066147	11.980	<2e-16 ***
ln_cpi.l1	-9.094482	6.555361	-1.387	0.169
ln_gdp.l1	3.586063	2.334147	1.536	0.128
ln_m1.l1	-0.383726	0.833854	-0.460	0.646
nc_sdr.l1	-0.305167	0.214570	-1.422	0.158
brent.l1	0.002283	0.003141	0.727	0.469
trend	0.006003	0.014131	0.425	0.672

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.421 on 90 degrees of freedom

Multiple R-Squared: 0.9821, Adjusted R-squared: 0.9807

F-statistic: 705.5 on 7 and 90 DF, p-value: < 2.2e-16

Estimation results for equation ln\_cpi:

=====

ln\_cpi = rates.l1 + ln\_cpi.l1 + ln\_gdp.l1 + ln\_m1.l1 + nc\_sdr.l1 + brent.l1 + trend  
end

	Estimate	Std. Error	t value	Pr(> t )	
rates.l1	-7.311e-04	5.208e-04	-1.404	0.163838	
ln_cpi.l1	8.000e-01	5.161e-02	15.500	< 2e-16	***
ln_gdp.l1	6.850e-02	1.838e-02	3.727	0.000338	***
ln_m1.l1	-1.278e-03	6.565e-03	-0.195	0.846073	
nc_sdr.l1	-3.231e-04	1.689e-03	-0.191	0.848775	
brent.l1	7.615e-05	2.473e-05	3.080	0.002748	**
trend	3.923e-04	1.113e-04	3.526	0.000666	***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.003315 on 90 degrees of freedom

Multiple R-Squared: 1, Adjusted R-squared: 1

F-statistic: 2.607e+07 on 7 and 90 DF, p-value: < 2.2e-16

Estimation results for equation ln\_gdp:

=====

ln\_gdp = rates.l1 + ln\_cpi.l1 + ln\_gdp.l1 + ln\_m1.l1 + nc\_sdr.l1 + brent.l1 + trend  
end

	Estimate	Std. Error	t value	Pr(> t )	
rates.l1	-8.546e-04	1.288e-03	-0.663	0.509	
ln_cpi.l1	-9.919e-02	1.277e-01	-0.777	0.439	
ln_gdp.l1	1.048e+00	4.545e-02	23.067	<2e-16	***
ln_m1.l1	-1.313e-02	1.624e-02	-0.809	0.421	
nc_sdr.l1	-3.151e-05	4.178e-03	-0.008	0.994	
brent.l1	4.930e-05	6.116e-05	0.806	0.422	
trend	2.223e-04	2.752e-04	0.808	0.421	

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.008199 on 90 degrees of freedom

Multiple R-Squared: 1, Adjusted R-squared: 1

F-statistic: 3.641e+07 on 7 and 90 DF, p-value: < 2.2e-16

Estimation results for equation ln\_m1:

=====

ln\_m1 = rates.l1 + ln\_cpi.l1 + ln\_gdp.l1 + ln\_m1.l1 + nc\_sdr.l1 + brent.l1 + trend  
end

	Estimate	Std. Error	t value	Pr(> t )
rates.l1	-0.0033496	0.0039236	-0.854	0.3955

ln_cpi.l1	-0.5509978	0.3888426	-1.417	0.1599
ln_gdp.l1	0.3261194	0.1384540	2.355	0.0207 *
ln_m1.l1	0.8778565	0.0494615	17.748	<2e-16 ***
nc_sdr.l1	-0.0106902	0.0127276	-0.840	0.4032
brent.l1	0.0003336	0.0001863	1.791	0.0767 .
trend	0.0011681	0.0008382	1.394	0.1669

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02497 on 90 degrees of freedom

Multiple R-Squared: 1, Adjusted R-squared: 1

F-statistic: 5.236e+06 on 7 and 90 DF, p-value: < 2.2e-16

Estimation results for equation nc\_sdr:

=====

nc\_sdr = rates.l1 + ln\_cpi.l1 + ln\_gdp.l1 + ln\_m1.l1 + nc\_sdr.l1 + brent.l1 + trend

	Estimate	Std. Error	t value	Pr(> t )
rates.l1	-0.0099785	0.0179083	-0.557	0.57878
ln_cpi.l1	1.1267583	1.7747607	0.635	0.52712
ln_gdp.l1	0.3410926	0.6319335	0.540	0.59070
ln_m1.l1	-0.6037489	0.2257529	-2.674	0.00889 **
nc_sdr.l1	0.8182793	0.0580914	14.086	< 2e-16 ***
brent.l1	0.0003224	0.0008502	0.379	0.70548
trend	-0.0026180	0.0038258	-0.684	0.49555

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.114 on 90 degrees of freedom

Multiple R-Squared: 0.9946, Adjusted R-squared: 0.9942

F-statistic: 2368 on 7 and 90 DF, p-value: < 2.2e-16

Estimation results for equation brent:

=====

brent = rates.l1 + ln\_cpi.l1 + ln\_gdp.l1 + ln\_m1.l1 + nc\_sdr.l1 + brent.l1 + trend

	Estimate	Std. Error	t value	Pr(> t )
rates.l1	-0.58589	1.79399	-0.327	0.745
ln_cpi.l1	83.06647	177.78865	0.467	0.641
ln_gdp.l1	-41.52604	63.30465	-0.656	0.514
ln_m1.l1	13.20107	22.61505	0.584	0.561
nc_sdr.l1	-4.02349	5.81937	-0.691	0.491
brent.l1	0.83896	0.08517	9.850	5.86e-16 ***
trend	-0.23363	0.38325	-0.610	0.544

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 11.42 on 90 degrees of freedom  
Multiple R-Squared: 0.9702, Adjusted R-squared: 0.9679  
F-statistic: 418.3 on 7 and 90 DF, p-value: < 2.2e-16

Covariance matrix of residuals:

	rates	ln_cpi	ln_gdp	ln_m1	nc_sdr	brent
rates	0.177270	4.130e-04	1.202e-03	-1.818e-03	2.017e-03	2.28881
ln_cpi	0.000413	1.099e-05	2.459e-07	-3.550e-06	3.191e-05	0.01998
ln_gdp	0.001202	2.459e-07	6.722e-05	1.502e-05	-5.598e-05	0.01682
ln_m1	-0.001818	-3.550e-06	1.502e-05	6.237e-04	3.931e-05	-0.01187
nc_sdr	0.002017	3.191e-05	-5.598e-05	3.931e-05	1.299e-02	-0.17297
brent	2.288808	1.998e-02	1.682e-02	-1.187e-02	-1.730e-01	130.39206

Correlation matrix of residuals:

	rates	ln_cpi	ln_gdp	ln_m1	nc_sdr	brent
rates	1.00000	0.295896	0.348277	-0.17290	0.04202	0.47606
ln_cpi	0.29590	1.000000	0.009047	-0.04288	0.08445	0.52794
ln_gdp	0.34828	0.009047	1.000000	0.07335	-0.05990	0.17963
ln_m1	-0.17290	-0.042878	0.073349	1.00000	0.01381	-0.04162
nc_sdr	0.04202	0.084447	-0.059901	0.01381	1.00000	-0.13288
brent	0.47606	0.527936	0.179631	-0.04162	-0.13288	1.00000

Обратные корни характеристического уравнения получившейся модели VAR(1):

```
vars::roots(varfit3)
```

```
[1] 1.0000784 0.9434757 0.9434757 0.8367239 0.7274650 0.7274650
```

В модели есть один обратных корень, превосходящий по модулю единицу, что говорит о возможной коинтеграции. Проведем тест Йохансена, выбрав 3-й случай, т.е. в данных есть линейный тренд, в коинтеграционном пространстве есть константа, но нет тренда, что соответствует параметру `include="const"` при построении вспомогательной модели VECM с одноименной функцией в библиотеке `tsDyn`. Полученная статистика  $\lambda_{trace}$  и  $\lambda_{max}$  сравниваются с критическими точками статистики и в случае, если тестовая статистика больше критического значения, то отвергается:

$$H_0: r \leq r_0$$

Результаты тестов приведены ниже:

```
vecm1 <- VECM(varmat3, lag = 1, estim = "ML", include = "const")
ranktest1 <- rank.select(varmat3, lag = 4, fitMeasure = c("SSR", "LL"), returnModels = T)
ranktest2 <- rank.test(vecm1, type = c("eigen", "trace"), cval = 0.05)

summary(ranktest1)
```

```
Best AIC: rank= 5 lag= 2
Best BIC: rank= 0 lag= 1
Best HQ : rank= 1 lag= 1
```

Best number of lags:

	r=0	r=1	r=2	r=3	r=4	r=5	r=6
AIC	1	2	2	2	2	2	2
BIC	1	1	1	1	1	1	1
HQ	1	1	1	1	1	1	1

`summary(ranktest2)`

	r	trace	trace_pval	trace_pval_T	eigen	eigen_pval
1	0	84.556014732	0.2296	0.3191	40.137822933	0.04521
2	1	44.418191799	0.8461	0.8821	17.943920477	0.87229
3	2	26.474271322	0.8704	0.8907	11.150632660	0.95084
4	3	15.323638662	0.7628	0.7771	9.814665165	0.76339
5	4	5.508973497	0.7533	0.7605	5.501286160	0.68113
6	5	0.007687337	0.9301	0.9315	0.007687337	0.93014

Исходя из теста Йохансена и тестов на основе информационных критериев, лучшая модель VECM будет специфицирована при лаге = 1, ранг = 1. Построим такую модель VECM(1):

```
vecm2 <- VECM(varmat3, lag = 1, estim = "ML", include = "const", r = 1)
summary(vecm2)
```

```
#####
###Model VECM
#####
```

```
Full sample size: 98      End sample size: 96
Number of variables: 6   Number of estimated slope parameters 48
AIC -2875.24      BIC -2739.33      SSR 11356.99
Cointegrating vector (estimated by ML):
      rates   ln_cpi   ln_gdp   ln_m1   nc_sdr   brent
r1      1 192.4633 -170.4565 10.99856 -0.6888292 -0.1639221
```

	ECT	Intercept
Equation rates	0.0307(0.0144)*	37.6192(17.6829)*
Equation ln_cpi	-0.0002(0.0001)*	-0.2954(0.1414)*
Equation ln_gdp	0.0007(0.0002)**	0.8967(0.2771)**
Equation ln_m1	-0.0020(0.0009)*	-2.4578(1.0669)*
Equation nc_sdr	-0.0002(0.0041)	-0.2237(5.0810)
Equation brent	1.1052(0.3857)**	1356.8832(473.4865)**
	rates -1	ln_cpi -1
Equation rates	0.0975(0.1239)	1.5158(14.4183)
Equation ln_cpi	-0.0007(0.0010)	-0.2248(0.1153).
Equation ln_gdp	0.0049(0.0019)*	0.1202(0.2260)
Equation ln_m1	0.0079(0.0075)	-1.1275(0.8699)
Equation nc_sdr	-0.0066(0.0356)	3.9118(4.1429)
Equation brent	-3.8274(3.3184)	101.2424(386.0701)
	ln_gdp -1	ln_m1 -1
Equation rates	9.7867(6.2559)	3.0533(1.7234).



Equation ln_cpi	0.0336(0.0500)	0.0164(0.0138)
Equation ln_gdp	0.2653(0.0980)**	0.0640(0.0270)*
Equation ln_m1	0.0312(0.3774)	-0.1787(0.1040).
Equation nc_sdr	1.6184(1.7976)	-0.3340(0.4952)
Equation brent	230.4190(167.5108)	62.3288(46.1474)
	nc_sdr -1	brent -1
Equation rates	-0.2593(0.3797)	0.0058(0.0048)
Equation ln_cpi	-0.0004(0.0030)	6.8e-05(3.8e-05).
Equation ln_gdp	-0.0005(0.0060)	0.0002(7.4e-05)**
Equation ln_m1	-0.0062(0.0229)	-0.0001(0.0003)
Equation nc_sdr	-0.0276(0.1091)	-0.0007(0.0014)
Equation brent	-1.6518(10.1659)	0.1950(0.1272)

Матрица  $\Pi$  модели VECM(1), которая показывает значения коэффициентов в модели:

`coefPI(vecm2)`

	rates	ln_cpi	ln_gdp	ln_m1
Equation rates	0.0307188298	5.91224878	-5.23622520	0.337862998
Equation ln_cpi	-0.0002436295	-0.04688976	0.04152825	-0.002679575
Equation ln_gdp	0.0007280281	0.14011872	-0.12409714	0.008007263
Equation ln_m1	-0.0020118793	-0.38721302	0.34293797	-0.022127782
Equation nc_sdr	-0.0001586456	-0.03053347	0.02704218	-0.001744874
Equation brent	1.1052450258	212.71915585	-188.39623385	12.156107511
	nc_sdr	brent		
Equation rates	-0.0211600263	-5.035494e-03		
Equation ln_cpi	0.0001678191	3.993625e-05		
Equation ln_gdp	-0.0005014870	-1.193399e-04		
Equation ln_m1	0.0013858412	3.297914e-04		
Equation nc_sdr	0.0001092797	2.600551e-05		
Equation brent	-0.7613250219	-1.811740e-01		

Проведем оценку адекватности модели VECM(1).

Убедимся, что в модели отсутствует автокорреляция:

`Box.test(vecm2$residuals[,1], type= "Ljung-Box")`

Box-Ljung test

data: vecm2\$residuals[, 1]  
X-squared = 0.026595, df = 1, p-value = 0.8705

`Box.test(vecm2$residuals[,2], type= "Ljung-Box")`

Box-Ljung test

data: vecm2\$residuals[, 2]  
X-squared = 0.017536, df = 1, p-value = 0.8946

`Box.test(vecm2$residuals[,3], type= "Ljung-Box")`

Box-Ljung test

```
data: vecm2$residuals[, 3]
X-squared = 2.4853, df = 1, p-value = 0.1149
Box.test(vecm2$residuals[,4], type= "Ljung-Box")
```

Box-Ljung test

```
data: vecm2$residuals[, 4]
X-squared = 0.012538, df = 1, p-value = 0.9108
Box.test(vecm2$residuals[,5], type= "Ljung-Box")
```

Box-Ljung test

```
data: vecm2$residuals[, 5]
X-squared = 0.029311, df = 1, p-value = 0.8641
Box.test(vecm2$residuals[,6], type= "Ljung-Box")
```

Box-Ljung test

```
data: vecm2$residuals[, 6]
X-squared = 0.0028073, df = 1, p-value = 0.9577
```

Получается, что во всех уровнях модели VECM(1) отвергается гипотеза о наличии автокорреляции в остатках на 5% уровне значимости.

Таким образом модели полученные при оценивании VECM(1) с помощью теста Йохансена не совпадают с моделями ЕСМ, полученные с помощью процедуры Ингла-Грейнджера. Объясняться это может тем, что модели ЕСМ оцениваются с помощью МНК, в отличие от VECM, где используется ММП. Для несмещенности МНК требуется нормальность остатков, что трудно достигается на небольших выборках.

## 7. Выводы

В работе были рассмотрены и составлены внимательно все предполагаемые модели (ARIMA, VAR, ЕСМ, VECM), были приведены все необходимые тесты с объяснениями для правильной спецификации и интерпретации результатов. Некоторые модели и ряды были представлены в графическом виде для удобства восприятия.

К сожалению, полученные модели не согласуются с полученными результатами статьи и не было установлено статистической взаимосвязи между шоками на рынке нефти и доходностью гос. облигаций, которые бы передавались через другие макроэкономические показатели. Это можно объяснить двумя причинами. Во-первых, на рынке нефти в связи с развитием фьючерсов на нефть, пришло все большее количество

участников со спекулятивными интересами, которые используют технический анализ для торговли "intraday". Технический анализ, в отличие от фундаментального анализа не предполагает анализ макроэкономических показателей на рынке нефти и поэтому взаимосвязь между изменениями ценами на нефть, ставкой и другими макроэкономическими показателями становится все менее значительной. Во-вторых, большая часть рассмотренного промежутка времени лежит после кризиса 2008 года. Таким образом, правительства ведущих экономик поменяли политику в отношении процентных ставок.